

大模型 API

OpenAI

- 基础介绍

快速开始	https://developers.openai.com/api/docs/quickstart
模型	https://developers.openai.com/api/docs/models
价格	https://developers.openai.com/api/docs/pricing
API SDK	https://developers.openai.com/api/docs/libraries

- 核心案例

提示词指南	https://developers.openai.com/api/docs/guides/prompt-guidance
案例：文本生成	https://developers.openai.com/api/docs/guides/text
案例：代码生成	https://developers.openai.com/api/docs/guides/code-generation
案例：视觉生成	https://developers.openai.com/api/docs/guides/images-vision
案例：音频生成	https://developers.openai.com/api/docs/guides/audio
案例：结构化输出	https://developers.openai.com/api/docs/guides/structured-outputs
案例：Responses API	https://developers.openai.com/api/docs/guides/migrate-to-responses
案例：Tools	https://developers.openai.com/api/docs/guides/tools https://developers.openai.com/api/docs/guides/function-calling

- Agents SDK

快速开始	https://developers.openai.com/api/docs/guides/agents https://developers.openai.com/api/docs/guides/agents/quickstart
Agent	https://developers.openai.com/api/docs/guides/agents/define-agents
Model	https://developers.openai.com/api/docs/guides/agents/models
Running agents	https://developers.openai.com/api/docs/guides/agents/running-agents
Sanbox agents	https://developers.openai.com/api/docs/guides/agents/sandboxes
Orchestration	https://developers.openai.com/api/docs/guides/agents/orchestration
Guardrails	https://developers.openai.com/api/docs/guides/agents/guardrails-approvals
Results and state	https://developers.openai.com/api/docs/guides/agents/results
Integrations and observability	https://developers.openai.com/api/docs/guides/agents/integrations-observability
Evaluate agent workflows	https://developers.openai.com/api/docs/guides/agent-evals
Voice agents	https://developers.openai.com/api/docs/guides/voice-agents
Agent Builder	https://developers.openai.com/api/docs/guides/agent-builder

- Tools

Web search	https://developers.openai.com/api/docs/guides/tools-web-search
MCP	https://developers.openai.com/api/docs/guides/tools-connectors-mcp
Skills	https://developers.openai.com/api/docs/guides/tools-skills
Shell	https://developers.openai.com/api/docs/guides/tools-shell
Computer use	https://developers.openai.com/api/docs/guides/tools-computer-use
File search	https://developers.openai.com/api/docs/guides/tools-file-search https://developers.openai.com/api/docs/guides/retrieval
Tool search	https://developers.openai.com/api/docs/guides/tools-tool-search
Code Interpreter	https://developers.openai.com/api/docs/guides/tools-code-interpreter

- Run and scale

Conversation state	https://developers.openai.com/api/docs/guides/conversation-state
Background mode	https://developers.openai.com/api/docs/guides/background
Streaming	https://developers.openai.com/api/docs/guides/streaming-responses
WebScket mode	https://developers.openai.com/api/docs/guides/websocket-mode
Webhooks	https://developers.openai.com/api/docs/guides/webhooks
File inputs	https://developers.openai.com/api/docs/guides/file-inputs
Context management	https://developers.openai.com/api/docs/guides/compaction https://developers.openai.com/api/docs/guides/token-counting https://developers.openai.com/api/docs/guides/prompt-caching
Prompting	https://developers.openai.com/api/docs/guides/prompting https://developers.openai.com/api/docs/guides/prompt-engineering https://developers.openai.com/api/docs/guides/citation-formatting
Reasoning	https://developers.openai.com/api/docs/guides/reasoning https://developers.openai.com/api/docs/guides/reasoning-best-practices

- Chat Completion API

参数名	类型 / 可选值	含义
<code>messages</code>	array	对话历史消息列表，每条包含 <code>role</code> （developer/system/user/assistant/tool/function）和 <code>content</code> 。支持文本、图像、音频等多模态内容。
<code>model</code>	string	使用的模型 ID，如 <code>gpt-4o</code> 、 <code>o3</code> 、 <code>gpt-5.4</code> 等，决定能力、性能与定价。
<code>temperature</code>	number (0–2)	采样温度。越高输出越随机，越低越确定。建议与 <code>top_p</code> 二选一调整。
<code>top_p</code>	number (0–1)	核采样概率质量阈值。例如 <code>0.1</code> 表示只考虑前 10% 概率的 token。
<code>n</code>	integer	为每条输入消息生成的聊天完成选项数量（默认 1）。越多成本越高。
<code>stop</code>	string/array	停止生成的 token 序列（最多 4 个），返回的文本不包含该序列。
<code>max_tokens</code>	integer	已弃用 。生成的最大 token 数。被 <code>max_completion_tokens</code> 替代。
<code>max_completion_tokens</code>	integer	生成的最大 token 总数，包含可见输出和推理 token。
<code>stream</code>	boolean	是否启用流式输出（SSE），实时返回生成内容。
<code>logprobs</code>	boolean	是否返回输出 token 的对数概率。
<code>top_logprobs</code>	integer (0–20)	每个 token 位置返回的最可能 token 数量，需 <code>logprobs=true</code> 。
<code>seed</code>	integer	确定性采样种子（Beta），配合 <code>system_fingerprint</code> 可复现结果。
<code>tools</code>	array	模型可调用的工具列表，如函数工具（function）或自定义工具（custom）。
<code>tool_choice</code>	"none" / "auto" / "required" / object	控制模型是否调用工具： <code>"none"</code> 不调用， <code>"auto"</code> 自动决定， <code>"required"</code> 必须调用，或指定具体工具。
<code>parallel_tool_calls</code>	boolean	是否启用并行工具调用（函数调用）。
<code>response_format</code>	object	指定输出格式： <code>{"type": "text"}</code> 文本； <code>{"type": "json_object"}</code> JSON 模式； <code>{"type": "json_schema", ...}</code> 结构化输出。
<code>frequency_penalty</code>	number (-2 – 2)	根据 token 已有频率惩罚新 token，降低重复相同行的概率。
<code>presence_penalty</code>	number (-2 – 2)	根据 token 是否已出现惩罚新 token，鼓励谈论新主题。
<code>logit_bias</code>	map	将 token ID 映射到偏置值（-100 到 100），改变其生成概率。
<code>user</code>	string	正被替代 。终端用户标识，用于缓存和安全。建议改用 <code>prompt_cache_key</code> 或 <code>safety_identifier</code> 。

<code>prompt_cache_key</code>	string	用于缓存相似请求，提高缓存命中率。
<code>prompt_cache_retention</code>	"in_memory" / "24h"	提示缓存的保留策略， <code>"24h"</code> 可延长至 24 小时。
<code>safety_identifier</code>	string	稳定标识符，帮助检测违反使用策略的用户（建议哈希处理）。
<code>store</code>	boolean	是否存储本次请求输出，用于模型蒸馏或评估。
<code>metadata</code>	object	最多 16 个键值对，附加结构化信息，可被 API 或仪表板查询。
<code>service_tier</code>	"auto" / "default" / "flex" / "scale" / "priority"	服务处理层级，影响性能与定价。
<code>reasoning_effort</code>	"none"/"minimal"/"low"/"medium"/"high"/"xhigh"	约束推理模型的思考强度，降低可提升速度和减少推理 token。
<code>verbosity</code>	"low" / "medium" / "high"	控制回答的详细程度。
<code>modalities</code>	array["text", "audio"]	输出模态。 <code>gpt-4o-audio-preview</code> 支持同时输出文本和音频。
<code>audio</code>	object	音频输出参数，包含 <code>format</code> （如 wav/mp3）和 <code>voice</code> （内置或自定义语音 ID）。
<code>web_search_options</code>	object	联网搜索工具选项，如搜索上下文大小（ <code>search_context_size</code> ）和用户位置（ <code>user_location</code> ）。
<code>prediction</code>	object	静态预测输出内容，用于快速匹配和生成已知内容（如文件重生成）。
<code>function_call</code>	deprecated	已弃用，改用 <code>tool_choice</code> 。强制模型调用指定函数。
<code>functions</code>	deprecated	已弃用，改用 <code>tools</code> 。函数定义列表。

- Responses API

参数名	类型 / 可选值	含义
model	string	使用的模型 ID，如 gpt-4o、o3-mini、gpt-5.4 等，决定能力与定价。
input	string / array	模型输入，可以是纯文本字符串，或包含文本、图像、文件的多模态内容列表（支持 user / assistant / system / developer 角色）。
instructions	string	系统或开发者指令，插入到模型上下文中，优先级高于用户消息。
conversation	string / object	所属对话的 ID。可自动管理多轮对话上下文。不能与 previous_response_id 同时使用。
previous_response_id	string	前一次响应的 ID，用于构建多轮对话。不能与 conversation 同时使用。
store	boolean	是否存储本次响应，便于后续检索（如评估、蒸馏）。
stream	boolean	是否启用流式输出（SSE），实时返回生成内容。
stream_options	object	流式选项，包含 include_obfuscation（是否添加随机字符以均衡载荷大小）。
background	boolean	是否在后台运行模型响应（异步处理）。
temperature	number (0-2)	采样温度。越高输出越随机，越低越确定。
top_p	number (0-1)	核采样概率阈值。例如 0.1 只考虑前 10% 概率的 token。
max_output_tokens	number	生成的最大 token 总数，包含可见输出和推理 token。
max_tool_calls	number	单次响应中允许调用的内置工具总数上限（跨所有工具）。
truncation	"auto" / "disabled"	截断策略：auto 自动丢弃早期内容以适应上下文窗口；disabled 超限则报错。
parallel_tool_calls	boolean	是否允许模型并行调用多个工具。
text	object	文本响应配置，包含 format（输出格式）和 verbosity（详细程度）。
text.format	object	输出格式：{"type": "text"} 纯文本；{"type": "json_object"} JSON 模式；{"type": "json_schema", ...} 结构化输出。
text.verbosity	"low" / "medium" / "high"	控制响应详细程度。
tools	array	模型可调用的工具列表，包括内置工具（文件搜索、网页搜索、代码解释器、图像生成、计算机控制等）、MCP 工具、函数调用（自定义工具）等。

tool_choice	"none" / "auto" / "required" / object	控制工具选择：none 不调用；auto 自动决定；required 必须调用；或指定具体工具（函数/MCP/自定义）。
reasoning	object	推理模型配置，包含 effort（推理强度）和 summary（摘要类型）。
reasoning.effort	"none" / "minimal" / "low" / "medium" / "high" / "xhigh"	约束推理模型的思考强度，降低可提升速度、减少推理 token。
reasoning.summary	"auto" / "concise" / "detailed"	推理过程的摘要类型，用于调试和可解释性。
prompt	object	引用可复用的提示模板，包含 id、variables（变量映射）和 version（版本）。
prompt_cache_key	string	用于缓存相似请求，提高缓存命中率。
prompt_cache_retention	"in_memory" / "24h"	提示缓存的保留策略，"24h" 可延长至 24 小时。
safety_identifier	string	稳定标识符，帮助检测违反使用策略的用户（建议哈希处理）。
metadata	object	最多 16 个键值对，附加结构化信息，可被 API 或仪表板查询。
service_tier	"auto" / "default" / "flex" / "scale" / "priority"	服务处理层级，影响性能与定价。
include	array	指定额外输出数据，如 file_search_call.results、web_search_call.action.sources、message.output_text.logprobs、reasoning.encrypted_content 等。
top_logprobs	integer (0–20)	每个 token 位置返回的最可能 token 数量（需模型支持）。
context_management	array	上下文管理配置，目前仅支持 compaction 类型及 compact_threshold 触发阈值。
user	string	已被 safety_identifier 和 prompt_cache_key 替代。终端用户标识，用于缓存和安全。

Anthropic

<https://platform.claude.com/docs/en/api/beta/messages/create>

后续补充

DeepSeek

- 基础介绍

快速开始	https://api-docs.deepseek.com/zh-cn/
模型 & 价格	https://api-docs.deepseek.com/zh-cn/quick_start/pricing
限速	https://api-docs.deepseek.com/zh-cn/quick_start/rate_limit
API SDK	https://developers.openai.com/api/docs/libraries

- 核心案例

思考模式	https://api-docs.deepseek.com/zh-cn/guides/thinking_mode
多轮对话	https://api-docs.deepseek.com/zh-cn/guides/multi_round_chat
对话前缀续写（Beta）	https://api-docs.deepseek.com/zh-cn/guides/chat_prefix_completion
FIM 补全（Beta）	https://api-docs.deepseek.com/zh-cn/guides/fim_completion
JSON Output	https://api-docs.deepseek.com/zh-cn/guides/json_mode
Tool Calls	https://api-docs.deepseek.com/zh-cn/guides/tool_calls
上下文硬盘缓存	https://api-docs.deepseek.com/zh-cn/guides/kv_cache

- API

功能 / 分类名称	API 文档链接
基本信息	https://api-docs.deepseek.com/zh-cn/api/deepseek-api
对话（Chat）	https://api-docs.deepseek.com/zh-cn/api/deepseek-api#
补全（Completions）	https://api-docs.deepseek.com/zh-cn/api/deepseek-api#
模型（Model）	https://api-docs.deepseek.com/zh-cn/api/deepseek-api#

阿里云百炼

<https://bailian.console.aliyun.com/>

字节火山

<https://www.volcengine.com/product/ark>