

AI Agent 基础概念

AI Agent，简称 Agent，是建立在大语言模型之上的智能应用。它不仅能回答问题，还能围绕用户目标进行规划、调用工具、执行动作，并根据结果不断调整。

普通大模型应用通常采用“用户提问—模型回答”的模式，而 Agent 更接近人类完成任务的过程：

1 | 观察 → 思考 → 行动 → 获取反馈 → 调整行动

Agent 的核心特点是主动性，通常表现为多步操作、多轮迭代、工具调用、自我检查和任务修正。

什么是 Agent

Agent 可以理解为一个为了实现目标而采取行动的智能系统。

1 | Agent = 感知 + 决策 + 行动 + 反馈 + 学习

感知 Observation

Agent 获取用户输入、网页内容、文件、数据库结果、程序日志等环境信息。

决策 Decision

Agent 根据目标、上下文和当前状态，判断下一步应该回答问题、调用工具、继续执行还是结束任务。

行动 Action

Agent 对外部环境执行具体操作，例如搜索资料、执行代码、修改文件、发送邮件或调用业务系统。

反馈 Feedback

工具执行结果、程序报错、测试结果和用户评价，都可以作为反馈，帮助 Agent 判断任务是否完成。

学习 Learning

Agent 可以通过上下文、历史记忆、用户偏好和任务经验优化后续行为。这里的学习不一定意味着重新训练模型，也可能只是更新记忆和执行策略。

Agent 的核心组成

规划 Planning

规划是将复杂目标拆分为可执行的子任务。

例如：

- 1

生成竞品报告
- 2

→ 确定竞品
- 3

→ 搜索资料
- 4

→ 对比功能
- 5

→ 分析优缺点
- 6

→ 生成报告

规划还包括反思与改进。Agent 会检查当前结果是否符合要求，并在必要时重新搜索、修改方案或再次执行。

记忆 Memory

记忆分为短期记忆和长期记忆。

短期记忆主要是当前对话、工具结果和任务状态，通常保存在模型上下文中。

长期记忆保存在数据库、向量库、文件系统或知识图谱中，可以记录用户偏好、历史任务和经验信息。

工具 Tools

工具让 Agent 能够连接外部世界，常见工具包括：

工具	作用
搜索工具	获取实时信息
RAG	查询知识库
代码工具	执行程序
数据库工具	查询或更新数据
浏览器工具	操作网页
业务 API	操作企业系统
MCP	统一连接外部工具

动作 Action

动作是 Agent 最终执行的操作，例如查询订单、修改代码、生成文件或创建日程。

对于付款、删除数据和修改生产环境等高风险操作，通常需要人工确认。

Workflow 与 Agent

Workflow 是由开发者提前定义执行路径的系统。

- 1

输入问题
- 2

→ 判断类型
- 3

→ 查询知识库
- 4

→ 生成答案

Agent 则由大语言模型根据任务动态决定步骤和工具。

- 1

分析任务
- 2

→ 选择工具
- 3

→ 执行动作
- 4

→ 检查结果
- 5

→ 调整计划

Workflow 的确定性更高，适合标准流程；Agent 的灵活性更强，适合步骤难以提前确定的开放任务。

实际生产系统通常采用混合方式：

- 1

Workflow 控制整体流程
- 2

+
- 3

Agent 处理开放问题
- 4

+
- 5

规则系统控制风险
- 6

+
- 7

人工确认高风险动作

四类常见 Agent 形态

低代码 workflow

代表产品包括 Dify、Coze。

用户通过拖拽节点搭建流程，本质上是“人定义的程序流程，加上 AI 的理解和生成能力”。

优点是入门简单、开发速度快，适合知识库问答和标准业务流程。

缺点是定制能力有限，不适合复杂状态管理和深度业务集成。

高代码 workflow

代表框架包括 LangGraph、OpenAI Agents SDK。

开发者使用 Python 定义流程、状态、工具、循环和路由逻辑。

优点是可控性和定制能力强，适合复杂企业应用。

缺点是学习和开发门槛较高，需要自行处理部署、监控、异常和安全问题。

Coding 或 CLI Agent

代表产品包括 Claude Code。

用户通过命令行与 Agent 交互，Agent 可以读取代码、修改文件、执行命令和运行测试。

优点是代码理解和任务拆解能力强，适合软件开发。

缺点是对用户技术能力要求较高，而且需要消耗较多 Token 和计算资源。

ChatUI Agent

代表产品包括 Manus、OpenClaw。

用户通过聊天界面描述目标，Agent 自主规划，并通过浏览器、文件和代码工具执行任务。

优点是使用门槛低，适合调研、办公和通用任务。

缺点是执行过程不够稳定，成本和 Token 消耗较高。

四类形态对比

类型	执行路径	自主性	确定性	适合场景
低代码工作流	人工预设	低	高	标准流程、知识库问答
高代码工作流	代码与模型共同决定	中	较高	企业级复杂应用
Coding Agent	模型动态决定	高	中	编程、测试、代码修改
ChatUI Agent	模型动态决定	高	较低	调研、办公、通用任务

常见专业名词

Agent Loop

Agent 持续执行“观察、思考、行动、反馈”的循环，直到任务完成。

ReAct

ReAct 是 Reasoning and Acting 的缩写，表示模型交替进行推理和工具调用。

Tool Calling

模型生成结构化工具调用请求，由程序执行工具，再把结果返回给模型。

MCP

MCP，即模型上下文协议，用于统一连接大语言模型和外部工具、数据源。

RAG

RAG，即检索增强生成。模型先查询外部知识库，再结合检索结果回答问题。

State

State 是任务运行状态，包括当前步骤、已完成任务、工具结果和重试次数。

Guardrails

Guardrails 是安全护栏，用于限制权限、危险操作、调用次数和数据访问范围。

Human in the Loop

Human in the Loop 指人在关键节点参与确认、审批和异常处理。

核心认识

Agent 的核心不是聊天界面，而是围绕目标持续采取行动。

大语言模型负责理解和决策，工具负责执行，记忆负责保存信息，反馈负责判断结果，工作流和安全机制负责控制过程。

Agent 也不是越自主越好。实际系统需要在效果、稳定性、成本、速度和安全性之间进行平衡。