

BERT: 用于语言理解的深度双向Transformer预训练

Jacob Devlin Ming-Wei Chang Kenton Lee Kristina Toutanova

谷歌人工智能语言

{jacobdevlin,mingweichang,kentonl,kristout}@google.com

摘要

我们介绍了一种名为BERT的新型语言表示模型，其全称为Bidirectional Encoder Representations from Transformers（来自Transformer的双向编码器表示）。与近期的语言表示模型（Peters et al., 2018a; Radford et al., 2018）不同，BERT旨在通过在所有层中同时结合左右上下文，从无标签文本中预训练深度双向表示。因此，预训练的BERT模型只需添加一个额外的输出层即可进行微调，从而在无需对特定任务架构进行大幅修改的情况下，创建出适用于问答和语言推理等广泛任务的最先进模型。

BERT在概念上简单，在实证上强大。它在11项自然语言处理任务上取得了新的最先进结果，包括将GLUE得分提升至80.5%（绝对提升7.7%），MultiNLI准确率提升至86.7%（绝对提升4.6%），SQuAD v1.1问答测试F1值提升至93.2（绝对提升1.5分），以及SQuAD v2.0测试F1值提升至83.1（绝对提升5.1分）。

1 引言

语言模型预训练已被证明能有效提升许多自然语言处理任务的性能（Dai and Le, 2015; Peters et al., 2018a; Radford et al., 2018; Howard and Ruder, 2018）。这些任务包括句子级任务，如自然语言推理（Bowman et al., 2015; Williams et al., 2018）和释义（Dolan and Brockett, 2005），旨在通过整体分析句子来预测它们之间的关系；以及词元级任务，如命名实体识别和问答，这些任务要求模型在词元级别生成细粒度的输出（Tjong Kim Sang and De Meulder, 2003; Rajpurkar et al., 2016）。

将预训练语言表示应用于下游任务有两种现有策略：*基于特征*和*微调*。基于特征的方法，例如ELMo（Peters et al., 2018a），使用包含预训练表示作为附加特征的任务特定架构。微调方法，例如生成式预训练Transformer（OpenAI GPT）（Radford et al., 2018），引入极少量的任务特定参数，并通过简单地微调所有预训练参数在下游任务上进行训练。这两种方法在预训练期间共享相同的目标函数，即使用单向语言模型来学习通用的语言表示。

我们认为当前的技术限制了预训练表示的能力，尤其是对于微调方法而言。主要的局限性在于标准语言模型是单向的，这限制了预训练期间可用的架构选择。例如，在OpenAI GPT中，作者使用了从左到右的架构，其中每个标记在Transformer的自注意力层中只能关注之前的标记（Vaswani et al., 2017）。这种限制对于句子级任务来说并非最优，并且在将基于微调的方法应用于问答等标记级任务时可能非常有害，因为在这些任务中，整合来自两个方向的上下文至关重要。

在本文中，我们通过提出BERT: Bidirectional Encoder Representations from Transformers，改进了基于微调的方法。BERT通过使用受完形填空任务（Taylor, 1953）启发而设计的“掩码语言模型”（MLM）预训练目标，缓解了前述的单向性限制。掩码语言模型会随机掩盖输入中的部分标记，其目标是预测被掩盖标记的原始词汇ID

仅基于其上下文进行词语预测。与从左到右的语言模型预训练不同，MLM目标使表示能够融合左侧和右侧的上下文，这使我们能够预训练一个深层的双向Transformer。除了掩码语言模型，我们还使用“下一句预测”任务来联合预训练文本对表示。我们论文的贡献如下：

- 我们展示了双向预训练对于语言表示的重要性。与使用单向语言模型进行预训练的Radford et al. (2018) 不同，BERT使用掩码语言模型来实现预训练的深度双向表示。这也与Peters et al. (2018a) 形成对比，后者使用独立训练的从左到右和从右到左语言模型的浅层拼接。

- 我们表明，预训练表示减少了对许多重度工程化的特定任务架构的需求。BERT是第一个基于微调的表示模型，在大量句子级和词元级任务上实现了最先进的性能，超越了许多特定任务架构。

- BERT 在 11 项自然语言处理任务上取得了最先进的成果。代码和预训练模型可在 <https://github.com/google-research/bert> 获取。

2 相关工作

预训练通用语言表示有着悠久的历史，我们将在本节中简要回顾最广泛使用的方法。

2.1 基于特征的无监督方法

学习广泛适用的词表示已成为数十年来活跃的研究领域，包括非神经方法 (Brown et al., 1992; Ando and Zhang, 2005; Blitzer et al., 2006) 和神经方法 (Mikolov et al., 2013; Pennington et al., 2014)。预训练词嵌入是现代自然语言处理系统不可或缺的一部分，相比从零开始学习的嵌入 (Turian et al., 2010) 提供了显著的改进。为了预训练词嵌入向量，人们使用了从左到右的语言建模目标 (Mnih and Hinton, 2009)，以及在左右上下文中区分正确与错误单词的目标 (Mikolov et al., 2013)。

这些方法已被推广到更粗的粒度，例如句子嵌入 (Kiros et al., 2015; Logeswaran and Lee, 2018) 或段落嵌入 (Le and Mikolov, 2014)。为了训练句子表示，先前的工作使用了以下目标：对候选下一句进行排序 (Jernite et al., 2017; Logeswaran and Lee, 2018)，在给定前一句表示的情况下从左到右生成下一句的词 (Kiros et al., 2015)，或去噪自编码器衍生的目标 (Hill et al., 2016)。

ELMo及其前身 (Peters et al., 2017, 2018a) 沿着不同的维度推广了传统的词嵌入研究。它们从一个从左到右和从右到左的语言模型中提取上下文敏感特征。每个标记的上下文表示是左到右和右到左表示的拼接。当将上下文词嵌入与现有的特定任务架构相结合时，ELMo在多个主要的NLP基准测试中取得了最先进的成果 (Peters et al., 2018a)，包括问答 (Rajpurkar et al., 2016)、情感分析 (Socher et al., 2013) 和命名实体识别 (Tjong Kim Sang and De Meulder, 2003)。Melamud et al. (2016) 提出通过一项任务来学习上下文表示，该任务使用LSTM从左右上下文预测单个单词。与ELMo类似，他们的模型是基于特征的，而不是深度双向的。Fedus et al. (2018) 表明完形填空任务可用于提高文本生成模型的鲁棒性。

2.2 无监督微调方法

与基于特征的方法一样，该方向的早期工作仅从无标签文本中预训练词嵌入参数 (Collobert and Weston, 2008)。

最近，能够生成上下文标记表示的句子或文档编码器已从无标签文本中进行预训练，并针对监督下游任务进行微调 (Dai and Le, 2015; Howard and Ruder, 2018; Radford et al., 2018)。这些方法的优势在于只需从头学习极少量的参数。至少部分归功于这一优势，OpenAI GPT (Radford et al., 2018) 在GLUE基准测试 (Wang et al., 2018a) 的许多句子级任务上取得了此前最先进的结果。从左到右的语言模型-




图1: BERT的整体预训练和微调流程。除了输出层之外, 预训练和微调中使用了相同的架构。相同的预训练模型参数被用于初始化不同下游任务的模型。在微调过程中, 所有参数都会被微调。[CLS]是添加到每个输入示例前面的特殊符号, 而[SEP]是一个特殊的分割标记(例如, 用于分隔问题/答案)。

和自动编码器目标已被用于预训练此类模型 (Howard and Ruder, 2018; Radford et al., 2018; Dai and Le, 2015)。

2.3 从监督数据中进行迁移学习

也有研究表明, 从具有大型数据集的有监督任务中进行有效迁移, 例如自然语言推理 (Conneau et al., 2017) 和机器翻译 (McCann et al., 2017)。计算机视觉研究也证明了从大型预训练模型进行迁移学习的重要性, 其中一种有效的方案是微调使用ImageNet预训练的模型 (Deng et al., 2009; Yosinski et al., 2014)。

3 BERT

在本节中, 我们介绍BERT及其详细实现。我们的框架包含两个步骤: 预训练和微调。在预训练期间, 模型在不同预训练任务的无标签数据上进行训练。对于微调, BERT模型首先使用预训练参数进行初始化, 然后使用来自下游任务的标签数据对所有参数进行微调。每个下游任务都有独立的微调模型, 尽管它们都使用相同的预训练参数进行初始化。图1中的问答示例将作为本节的运行示例。

BERT的一个显著特征是其在不同任务中采用统一的架构。存在微-

预训练架构与最终下游架构之间的差异。

模型架构 BERT的模型架构是一个多层双向Transformer编码器, 基于Vaswani等 (2017) 描述的原始实现, 并发布在tensor2tensor库中。¹ 由于Transformer的使用已变得普遍, 且我们的实现与原始实现几乎完全相同, 我们将省略对模型架构详尽的背景描述, 并建议读者参考Vaswani等 (2017) 以及优秀的指南, 如“The Annotated Transformer”。²

在这项工作中, 我们将层数 (即Transformer块) 表示为L, 隐藏层大小表示为H, 自注意力头数表示为A。³ 我们主要报告两种模型规模的结果: **BERT_{BASE}** (L=12, H=768, A=12, 总参数量=110M) 和 **BERT_{LARGE}** (L=24, H=1024, A=16, 总参数量=340M)。

BERT_{BASE} 被选择具有与 OpenAI GPT 相同的模型大小, 以便进行比较。然而, 关键在于, BERT Transformer 使用双向自注意力机制, 而 GPT Transformer 使用受限的自注意力机制, 其中每个标记只能关注其左侧的上下文。⁴

¹<https://github.com/tensorflow/tensor2tensor>

²<http://nlp.seas.harvard.edu/2018/04/03/attention.html>

³ 在所有情况下, 我们将前馈/滤波器大小设置为4H, 即当H=768时为3072, 当H=1024时为4096。

我们注意到, 在文献中, 双向Trans-

输入/输出表示 为了让BERT能够处理各种下游任务，我们的输入表示能够在一个标记序列中无歧义地表示单个句子和句子对（例如，〈问题，回答〉）。在本文中，“句子”可以是一段任意的连续文本，而不是实际的语言学句子。“序列”是指输入给BERT的标记序列，它可以是单个句子或打包在一起的两个句子。

我们使用包含30,000个词汇量的WordPiece嵌入（Wu et al., 2016）。每个序列的第一个标记始终是一个特殊的分类标记（[CLS]）。与该标记对应的最终隐藏状态被用作分类任务的聚合序列表示。句子对被打包成一个单一序列。我们通过两种方式区分这些句子。首先，我们用一个特殊标记（[SEP]）将它们分隔开。其次，我们为每个标记添加一个学习到的嵌入，以指示它属于句子A还是句子B。如图1所示，我们将输入嵌入表示为E，特殊[CLS]标记的最终隐藏向量表示为 $C \in \mathbb{R}^H$ ，第 i^{th} 个输入标记的最终隐藏向量表示为 $T_i \in \mathbb{R}^H$ 。

对于给定的标记，其输入表示是通过将相应的标记、段和位置嵌入相加构建的。这种构建过程的直观展示可见于图2。

3.1 预训练BERT

与Peters等人（2018a）和Radford等人（2018）不同，我们不使用传统的从左到右或从右到左的语言模型来预训练BERT。相反，我们使用本节中描述的两个无监督任务来预训练BERT。这一步骤展示在图1的左侧部分。

任务 #1：掩码语言模型 直观上，认为深度双向模型比从左到右模型或从左到右与从右到左模型的浅层拼接模型更强大是合理的。遗憾的是，标准条件语言模型只能从左到右或从右到左进行训练，因为双向条件建模会允许每个词间接“看到自己”，从而使模型在多层上下文中能轻易预测出目标词。

为了训练深度双向表示，我们简单地随机遮盖一定比例的输入标记，然后预测这些被遮盖的标记。我们将此过程称为“遮盖语言模型”（MLM），尽管在文献中它通常被称为完形填空任务（Taylor, 1953）。在这种情况下，与遮盖标记相对应的最终隐藏向量会被输入到词表上的输出softmax中，就像标准语言模型一样。在我们的所有实验中，我们随机遮盖每个序列中15%的所有WordPiece标记。与去噪自编码器（Vincent et al., 2008）不同，我们只预测被遮盖的单词，而不是重建整个输入。

虽然这使我们能够获得双向预训练模型，但缺点是在预训练和微调之间造成了不匹配，因为[MASK]标记在微调期间不会出现。为了缓解这一问题，我们并不总是用实际的[MASK]标记替换“被遮盖”的单词。训练数据生成器随机选择15%的标记位置进行预测。如果第 i 个标记被选中，我们以以下比例替换第 i 个标记：(1) 80%的时间替换为[MASK]标记 (2) 10%的时间替换为随机标记 (3) 10%的时间保持第 i 个标记不变。然后， T_i 将使用交叉熵损失来预测原始标记。我们在附录C.2中比较了该过程的变体。

任务 #2：下一句预测 (NSP)

许多重要的下游任务，如问答（QA）和自然语言推理（NLI），都基于理解两个句子之间的关系，而这无法通过语言建模直接捕捉。为了训练一个能够理解句子关系的模型，我们针对一个二值化的下一句预测任务进行预训练，该任务可以从任何单语语料库中轻松生成。具体而言，在为每个预训练样本选择句子A和B时，50%的情况下B是紧跟在A之后的实际下一句（标记为IsNext），另外50%的情况下它是来自语料库的随机句子（标记为NotNext）。正如我们在图1中所示，C被用于下一句预测（NSP）。⁵尽管该任务很简单，但我们在第5.1节中证明，针对该任务的预训练对QA和NLI都非常有益。⁶

前者通常被称为“Transformer编码器”，而仅包含左上下文的版本被称为“Transformer解码器”，因为它可用于文本生成。

⁵最终模型在NSP上达到了97%-98%的准确率。

⁶向量C在没有微调的情况下不是一个有意义的句子表示，因为它是在NSP上训练的。




图2：BERT输入表示。输入嵌入是标记嵌入、分段嵌入和位置嵌入之和。

NSP任务与Jernite et al. (2017) 和Logeswaran and Lee (2018) 中使用的表示学习目标密切相关。然而，在先前的工作中，仅有句子嵌入被迁移到下游任务，而BERT则迁移所有参数来初始化最终任务的模型参数。

预训练数据 预训练过程在很大程度上遵循了现有的语言模型预训练文献。对于预训练语料库，我们使用了BooksCorpus (8亿词) (Zhu et al., 2015) 和英文维基百科 (25亿词)。对于维基百科，我们仅提取文本段落，忽略列表、表格和标题。使用文档级语料库而非像Billion Word Benchmark (Chelba et al., 2013) 那样打乱的句子级语料库至关重要，以便提取长连续序列。

3.2 微调BERT

微调非常直接，因为Transformer中的自注意力机制允许BERT通过更换适当的输入和输出来建模许多下游任务——无论它们涉及单文本还是文本对。对于涉及文本对的应用，一种常见的模式是在应用双向交叉注意力之前独立编码文本对，例如Parikh et al. (2016); Seo et al. (2017)。BERT则使用自注意力机制来统一这两个阶段，因为使用自注意力编码拼接的文本对实际上包含了两个句子之间的双向交叉注意力。

对于每个任务，我们只需将任务特定的输入和输出接入BERT，并对所有参数进行端到端微调。在输入端，来自预训练的句子A和句子B分别类似于（1）释义任务中的句子对，（2）蕴含任务中的假设-前提对，（3）问答任务中的问题-段落对，以及

（4）文本分类或序列标注中的退化文本- $\emptyset$ 对。在输出端，标记表示被送入用于标记级任务（如序列标注或问答）的输出层，而[CLS]表示被送入用于分类任务（如蕴含或情感分析）的输出层。

与预训练相比，微调相对廉价。本文中的所有结果在单个Cloud TPU上最多只需1小时，或在GPU上只需几小时，即可从完全相同的预训练模型开始复现。⁷ 我们在第4节的相应子节中描述了特定任务的细节。更多细节可以在附录A.5中找到。

4 实验

在本节中，我们展示了BERT在11个NLP任务上的微调结果。

4.1 GLUE

通用语言理解评估 (GLUE) 基准 (Wang et al., 2018a) 是一系列多样化的自然语言理解任务集合。GLUE数据集的详细描述包含在附录B.1中。

为了在GLUE上进行微调，我们将输入序列（针对单句或句子对）表示为第3节中所描述的形式，并使用与第一个输入标记 ([CLS]) 相对应的最终隐藏向量 $C \in \mathbb{R}^H$ 作为聚合表示。微调过程中引入的唯一新参数是分类层权重 $W \in \mathbb{R}^{K \times H}$ ，其中K是标签的数量。我们使用C和W计算标准分类损失，即 $\log(\text{softmax}(CW^T))$ 。

⁷ 例如，BERT SQuAD模型可以在单个Cloud TPU上训练约30分钟，以达到91.0%的Dev F1分数。

⁸ 参见 <https://gluebenchmark.com/faq> 中的 (10)。

系统	MNLI-(m/mm)	QQP	QNLI	STS-B	MRPC	RTE	平均
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	74.0
双向长短期记忆网络+嵌入式语言模型+注意力机制	76.4/76.1	64.8	79.8	90.4	36.0	73.3	71.0
OpenAI GPT	82.1/81.4	70.3	87.4	91.3	45.4	80.0	75.1
BERTBASE	84.6/83.4	71.2	90.5	93.5	52.1	85.8	79.6
BERTLARGE	86.7/85.9	72.1	92.7	94.9	60.5	86.5	82.1

表 1: GLUE 测试结果, 由评估服务器评分 (<https://gluebenchmark.com/leaderboard>)。每个任务下方的数字表示训练样本的数量。“平均值”列与官方 GLUE 评分略有不同, 因为我们排除了有问题的 WNLI 数据集。⁸ BERT 和 OpenAI GPT 是单模型、单任务。QQP 和 MRPC 报告 F1 分数, STS-B 报告斯皮尔曼相关系数, 其他任务报告准确率分数。我们排除了将 BERT 作为其组件之一的条目。

我们使用32的批次大小, 在所有GLUE任务上对数据进行3个轮次的微调。对于每个任务, 我们在开发集上选择了最佳的微调学习率 (在5e-5、4e-5、3e-5和2e-5中)。此外, 对于BERT_{LARGE}, 我们发现微调在小数据集上有时不稳定, 因此我们进行了多次随机重启, 并在开发集上选择了最佳模型。在随机重启中, 我们使用相同的预训练检查点, 但执行不同的微调数据打乱和分类器层初始化。⁹

结果如表 1 所示。BERT_{BASE} 和 BERT_{LARGE} 在所有任务上均大幅领先所有系统, 相比之前的最先进技术, 分别获得了 4.5% 和 7.0% 的平均准确率提升。需要注意的是, 除了注意力掩码之外, BERT_{BASE} 和 OpenAI GPT 在模型架构方面几乎完全相同。在最大且被报道最广泛的 GLUE 任务 MNLI 上, BERT 获得了 4.6% 的绝对准确率提升。在官方 GLUE 排行榜¹⁰ 上, BERT_{LARGE} 获得了 80.5 的分数, 而截至本文撰写之日, OpenAI GPT 的得分为 72.8。

我们发现 BERT_{LARGE} 在所有任务上都显著优于 BERT_{BASE}, 尤其是在训练数据非常少的任务上。模型规模的影响在第 5.2 节中得到了更深入的探讨。

4.2 SQuAD v1.1

斯坦福问答数据集 (SQuAD v1.1) 是一个包含10万个众包问答对的集合 (Rajpurkar 等人, 2016)。给定一个问题和一段来自

包含答案的维基百科, 任务是预测文章中的答案文本跨度。

如图1所示, 在问答任务中, 我们将输入的问题和段落表示为一个单一的打包序列, 其中问题使用A嵌入, 段落使用B嵌入。在微调期间, 我们仅引入一个起始向量 $S \in \mathbb{R}^H$ 和一个结束向量 $E \in \mathbb{R}^H$ 。单词 i 作为答案跨度起始位置的概率计算为 T_i 与 S 的点积, 随后对段落中的所有单词进行softmax: $P_i = e^{S \cdot T_i} / \sum_j e^{S \cdot T_j}$ 。答案跨度结束位置使用类似的公式。从位置 i 到位置 j 的候选跨度的得分定义为 $S \cdot T_i + E \cdot T_j$, 并使用 $j \geq i$ 的最大得分跨度作为预测。训练目标是正确起始位置和结束位置对数似然的和。我们以5e-5的学习率和32的批大小进行3个轮次的微调。

表 2 展示了排行榜顶部的条目以及顶级已发表系统的结果 (Seo 等人, 2017; Clark 和 Gardner, 2018; Peters 等人, 2018a; Hu 等人, 2018)。SQuAD 排行榜上的顶级结果没有可用的最新公开系统描述,¹¹ 并且允许在训练其系统时使用任何公开数据。因此, 我们在我们的系统中使用了适度的数据增强, 首先在 TriviaQA (Joshi 等人, 2017) 上进行微调, 然后再在 SQuAD 上进行微调。

我们表现最好的系统在集成时比排行榜第一的系统高出 +1.5 F1, 作为单一系统时高出 +1.3 F1。事实上, 我们的单一 BERT 模型在 F1 分数方面优于排名第一的集成系统。在没有 TriviaQA 微调

⁹ GLUE数据集分布不包含测试标签, 我们仅为BERT_{BASE}和BERT_{LARGE}各进行了一次GLUE评估服务器提交。

¹⁰ <https://gluebenchmark.com/leaderboard>

¹¹ QANet在Yu等(2018)中被描述, 但该系统在发表后有了实质性的改进。

系统	开发测试 EM F1
顶级排行榜系统（2018年12月10日）	
人类 -- 82.3	91.2
#1 集成 - nlnet -- 86.0	91.7
#2 集成 - QANet -- 84.5	90.5
已发布	
BiDAF+ELMo (单) - 85.6 -	85.8
R.M. Reader (Ensemble) 81.2 87.9 82.88.5	
我们的	
BERT _{QA} (单) 80.8 88.5 -	-
BERT _{LARGE} (单体)	-
BERT _{LARGE} (集成) 85.8 91.8 -	-
BERT _{LARGE} (Sgl.+TriviaQA) 84.2 91.1 85.1	
BERT _{LARGE} (Ens.+TriviaQA) 83.6 92.2 87.4	

表 2: SQuAD 1.1 结果。BERT 集成是 7x 系统，使用了不同的预训练检查点和微调种子。

系统	开发测试 EM F1 F1
顶级排行榜系统（2018年12月10日）	
人类	86.9 89.0
#1 单个 - MIR-MRC (F-Net)	74.8 78.0
#2 单人 - nlnet	74.2 77.1
已发布	
unet (集成)	71.4 74.9
SLQA+ (单)	71.4 74.4
我们的 BERT _{LARGE} (单)	80.9 83.1

表3: SQuAD 2.0结果。我们排除了将BERT作为其组件之一的条目。

微调数据，我们仅损失 0.1-0.4 F1，仍大幅领先所有现有系统。¹²

4.3 SQuAD v2.0

SQuAD 2.0 任务扩展了 SQuAD 1.1 的问题定义，允许在提供的段落中不存在简短答案的可能性，从而使问题更加真实。

我们使用一种简单的方法来扩展用于此任务的 SQuAD v1.1 BERT 模型。我们将没有答案的问题视为答案跨度在 [CLS] 标记处开始和结束。开始和结束答案跨度位置的概率空间被扩展，以包含 [CLS] 标记的位置。对于预测，我们将无答案跨度的得分： $s_{\text{null}} = S \cdot C + E \cdot C$ 与最佳非空跨度的得分进行比较。

¹² 我们使用的TriviaQA数据由TriviaQA-Wiki中的 段落组成，这些段落由文档的前400个标记构成，并且包含所提供的可能答案中的至少一个。

系统	开发测试
ESIM+GloVe	51.9 52.7
ESIM+ELMo	59.1 59.2
OpenAI GPT	- 78.0
BERT _{QA}	86.6 86.3
BERT _{LARGE}	86.6 86.3
人类（专家） [†]	- 85.0
人类（5个注释） [†]	-88.0

表 4: SWAG 开发与测试准确率。[†] 人类表现使用 100 个样本进行测量，如 SWAG 论文中所述。

$s_{i,j} = \max_{j \geq i} S \cdot T_i + E \cdot T_j$ 。当 $s_{i,j} > s_{\text{null}} + \tau$ 时，我们预测一个非空答案，其中阈值 τ 在开发集上选择以最大化 F1。我们没有在这个模型中使用 TriviaQA 数据。我们以 5e-5 的学习率和 48 的批大小进行了 2 个轮次的微调。

与之前的排行榜条目和顶级发表作品（Sun et al., 2018; Wang et al., 2018b）相比的结果显示在表3中，不包括将BERT作为其组件之一的系统。我们观察到相比之前的最佳系统，F1值提升了+5.1。

4.4 SWAG

对抗生成情境（SWAG）数据集包含11.3万个句子对补全示例，用于评估基于常识的推理（Zellers et al., 2018）。给定一个句子，任务是从四个选项中选出最合理的后续内容。

在SWAG数据集上进行微调时，我们构建了四个输入序列，每个序列都包含给定句子（句子A）与一个可能的后续句子（句子B）的拼接。引入的唯一特定任务参数是一个向量，该向量与[CLS]标记表示C的点积表示每个选项的分数，并使用softmax层进行归一化。

我们以2e-5的学习率和16的批次大小对模型进行了3个轮次的微调。结果如表4所示。BERT_{LARGE} 比作者的基准ESIM+ELMo系统高出+27.1%，比OpenAI GPT高出8.3%。

5 消融实验

在本节中，我们对BERT的多个方面进行消融实验，以便更好地理解它们的相对重要性。额外的

任务	开发集	开发集	开发集	开发集	开发集
	(MNLI-m QNLI MRPC SSTe2 SQuAD				
BERTBASE	83.9	88.9	86.3	92.7	88.9
No NSP	83.9	84.9	86.5	92.6	87.9
LTR & No NSP	82.1	84.3	77.5	92.1	77.8
+ 双向长短期记忆网络	82.1	84.1	75.7	91.6	84.9

表 5: 使用 BERT_{BASE} 架构的预训练任务消融实验。“No NSP”表示在没有下一句预测任务的情况下进行训练。“LTR & No NSP”表示像 Open AI GPT 一样，作为从左到右的语言模型进行训练，且不包含下一句预测任务。“+ BiLSTM”表示在微调过程中，在“LTR + No NSP”模型之上添加了一个随机初始化的 BiLSTM。

消融实验可以在附录 C 中找到。

5.1 预训练任务的影响

我们通过评估两个预训练目标来证明BERT深度双向性的重要性，这两个目标使用了与BERTBASE完全相同的预训练数据、微调方案和超参数：

无NSP：一种使用“掩码语言模型”（MLM）训练的双向模型，但不包含“下一句预测”（NSP）任务。**LTR与无NSP**：一种仅使用左侧上下文的模型，它使用标准的从左到右（LTR）语言模型进行训练，而非MLM。在微调阶段也应用了仅限左侧的约束，因为移除该约束会引入预训练与微调之间的不匹配，从而降低下游任务的性能。此外，该模型在预训练时也未包含NSP任务。这与OpenAI GPT直接可比，但使用了我们更大的训练数据集、输入表示方法以及微调方案。

我们首先考察NSP任务带来的影响。在表 5中，我们展示了移除NSP会显著损害QNLI、MNLI和SQuAD 1.1上的性能。接下来，我们通过比较“无 NSP”与“LTR & No NSP”来评估训练双向表示的影响。LTR模型在所有任务上的表现均差于MLM模型，其中在MRPC和SQuAD上下降幅度较大。

对于SQuAD，直观上很明显LTR模型在标记预测方面表现不佳，因为标记级别的隐藏状态没有右侧上下文。为了诚意地尝试增强LTR系统，我们在顶部添加了一个随机初始化的BiLSTM。这确实显著改善了SQuAD上的结果，但是

结果仍然远差于预训练双向模型的表现。BiLSTM 损害了在 GLUE 任务上的性能。

我们认识到，也可以训练独立的LTR和RTL模型，并将每个标记表示为这两个模型的拼接，就像ELMo所做的那样。然而：(a) 这比单个双向模型贵一倍；(b) 这对于问答等任务来说不直观，因为RTL模型将无法根据问题来确定答案；(c) 这严格来说不如深度双向模型强大，因为后者可以在每一层都使用左右上下文。

5.2 模型规模的影响

在本节中，我们探讨模型规模对微调任务准确性的影响。我们训练了若干个具有不同层数、隐藏单元和注意力头数的BERT模型，同时使用与前文所述相同的超参数和训练流程。

在选定的GLUE任务上的结果如表 6所示。在此表中，我们报告了5次随机重启微调的平均开发集准确率。我们可以看到，更大的模型在所有四个数据集上都带来了严格的准确率提升，即使是仅有3,600个标注训练样本且与预训练任务有显著差异的MRPC也是如此。同样令人惊讶的是，我们能够在相对于现有文献已经相当大的模型基础上实现如此显著的提升。例如，Vaswani et al. (2017) 中探索的最大Transformer为(L=6, H=1024, A=16)，编码器拥有1亿个参数，而我们在文献中发现的最大Transformer为(L=64, H=512, A=2)，拥有2.35亿个参数(Al-Rfou et al., 2018)。相比之下，BERT_{BASE}包含1.1亿个参数，而BERT_{LARGE}包含3.4亿个参数。

长期以来人们都知道，增加模型规模将导致在机器翻译和语言建模等大规模任务上持续改进，这由表 6 中显示的留出训练数据的LM困惑度所证明。然而，我们相信这是第一项令人信服地证明，只要模型经过充分预训练，扩展到极端模型规模也会在极小规模任务上带来巨大改进的工作。Peters等人 (2018b) 提出

将预训练双向语言模型从两层增加到四层对下游任务影响的结果不一，Melamud 等人 (2016) 顺带提到将隐藏层维度从 200 增加到 600 有所帮助，但进一步增加到 1,000 则没有带来进一步的提升。这两项先前的工作都使用了基于特征的方法——我们假设，当模型直接在下游任务上进行微调，并且仅使用极少量随机初始化的额外参数时，即使下游任务数据非常少，任务特定模型也能从更大、更具表达力的预训练表示中获益。

5.3 基于BERT的特征方法

迄今为止呈现的所有BERT结果都采用了微调方法，即在预训练模型上添加一个简单的分类层，并对所有参数进行下游任务的联合微调。然而，基于特征的方法（即从预训练模型中提取固定特征）具有一定的优势。首先，并非所有任务都能轻易地用Transformer编码器架构来表示，因此需要添加特定于任务的模型架构。其次，预先计算一次昂贵的训练数据表示，然后在此表示之上使用更廉价的模型运行多次实验，具有显著的计算优势。

在本节中，我们通过将BERT应用于CoNLL-2003命名实体识别（NER）任务（Tjong Kim Sang and De Meulder, 2003）来比较这两种方法。在BERT的输入中，我们使用一种保留大小写的WordPiece模型，并包含数据提供的最大文档上下文。遵循标准做法，我们将此表述为一个标注任务，但不使用CRF

超参数				验证集准确率		
#L	#H	#A	语言模型 (困惑度)	MNLI-m	MRPC	SST-2
3	768	12	5.84	77.9	79.8	88.4
6	768	3	5.24	80.6	82.2	90.7
6	768	12	4.68	81.9	84.8	91.3
12	768	12	3.99	84.4	86.7	92.9
12	1024	16	3.54	85.7	86.9	93.3
24	1024	16	3.23	86.6	87.8	93.7

表 6: BERT 模型规模的消融实验。#L = 层数；#H = 隐藏层大小；#A = 注意力头数。“LM (ppl)” 是预留训练数据的掩码语言模型困惑度。

系统	Dev F1测试 F1	
ELMo (Peters et al., 2018a)	95.7	92.2
CVT (Clark 等人, 2018)	-	92.6
CSE (Akbik 等人, 2018)	-	93.1
微调方法		
BERTBASE	96.4	92.8
BERTBASE	96.4	92.4
基于特征的方法 (BERTBASE)		
嵌入	91.0	-
倒数第二层隐藏	95.6	-
最后隐藏层	94.9	-
加权和最后四个隐藏层	95.9	-
拼接最后四个隐藏层	96.1	-
所有12层的加权和	95.5	-

表 7: CoNLL-2003 命名实体识别结果。超参数使用开发集进行选择。报告的开发集和测试集得分是使用这些超参数进行 5 次随机重启后的平均值。

输出层。我们将第一个子词的表示作为输入，传递给NER标签集上的词级分类器。

为了消融微调方法，我们应用基于特征的方法，通过从一个或多个层中提取激活值，而不微调BERT的任何参数。这些上下文嵌入被用作输入，输入到一个随机初始化的两层768维BiLSTM中，该BiLSTM位于分类层之前。

结果如表 7 所示。BERT 大与最先进的方法相比具有竞争力。表现最好的方法是将预训练Transformer的前四个隐藏层的标记表示进行拼接，这仅比微调整个模型低0.3 F1。这表明BERT对于微调和基于特征的方法都是有效的。

6 结论

由于语言模型的迁移学习带来的近期实证改进表明，丰富的无监督预训练是许多语言理解系统不可或缺的一部分。特别是，这些结果使得即使是低资源任务也能从深度单向架构中获益。我们的主要贡献是将这些发现进一步推广到深度双向架构，从而使同一个预训练模型能够成功应对广泛的自然语言处理任务。

参考文献

艾伦·阿克比克、邓肯·布莱斯和罗兰·沃尔格拉夫。2018。用于序列标注的上下文字符串嵌入。收录于《第27届国际计算语言学会议论文集》，第1638–1649页。

Rami Al-Rfou, Dokook Choe, Noah Constant, Mandy Guo, and Llion Jones. 2018. 具有更深自注意力的字符级语言建模。 *arXiv 预印本 arXiv:1808.04444*。

Rie Kubota Ando 和 Tong Zhang. 2005. 从多任务和无标签数据中学习预测结构的框架。 *Journal of Machine Learning Research*, 6(Nov):1817–1853。

Luisa Bentivogli, Bernardo Magnini, Ido Dagan, Hoa Trang Dang, 和 Danilo Giampiccolo。2009。第五届PASCAL文本蕴含识别挑战赛。

收录于TAC。NIST。

约翰·布利策、瑞安·麦克唐纳和费尔南多·佩雷拉。2006。结构对应学习的领域自适应。收录于《2006年自然语言处理经验方法会议论文集》，第120–128页。计算语言学协会。

Samuel R. Bowman, Gabor Angeli, Christopher Potts, and Christopher D. Manning. 2015. 用于学习自然语言推理的大型标注语料库。载于 *EMNLP*。计算语言学协会。

Peter F Brown, Peter V Desouza, Robert L Mercer, Vincent J Della Pietra, and Jenifer C Lai. 1992. 基于类的自然语言n-gram模型。 *计算语言学*, 18(4):467–479。

Daniel Cer, Mona Diab, Eneko Agirre, Inigo LopezGazpio, and Lucia Specia. 2017. [Semeval-2017 任务 1: 语义文本相似度多语言与跨语言评估](#)。收录于 *第11届语义评估国际研讨会论文集 (SemEval-2017)*, 第1–14页, 加拿大温哥华。计算语言学协会。

Ciprian Chelba, Tomas Mikolov, Mike Schuster, Qi Ge, Thorsten Brants, Phillipp Koehn, and Tony Robinson. 2013. 用于衡量统计语言模型进展的十亿词基准测试。 *arXiv preprint arXiv:1312.3005*。

Z. Chen, H. Zhang, X. Zhang, 和 L. Zhao. 2018. [Quora问题对](#)。

克里斯托弗·克拉克和马特·加德纳。2018。简单的多段落阅读理解。收录于《*ACL*》。

Kevin Clark, Minh-Thang Luong, Christopher D Manning, and Quoc Le. 2018. 跨视图训练的半监督序列建模。收录于《2018年自然语言处理经验方法会议论文集》，第1914–1925页。

Ronan Collobert 和 Jason Weston. 2008. 一种用于自然语言处理的统一架构：具有多任务学习的深度神经网络。收录于《第25届国际机器学习会议论文集》，第160–167页。ACM。

Alexis Conneau, Douwe Kiela, Holger Schwenk, Loïc Barrault, 和 Antoine Bordes. 2017. [从自然语言推理数据中监督学习通用句子表示](#)。收录于《2017年自然语言处理经验方法会议论文集》，第670–680页, 丹麦哥本哈根。计算语言学协会。

Andrew M Dai 和 Quoc V Le. 2015. 半监督序列学习。收录于《*神经信息处理系统进展*》，第3079–3087页。

J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, 和 L. FeiFei. 2009. ImageNet: 一个大规模分层图像数据库。收录于 *CVPR09*。

威廉·B·多兰和克里斯·布罗克特。2005。自动构建句子改写语料库。收录于《*第三届国际改写研讨会论文集 (IWP2005)*》。

William Fedus, Ian Goodfellow, and Andrew M Dai. 2018. Maskgan: Better text generation via filling in the . *arXiv preprint arXiv:1801.07736*。

Dan Hendrycks 和 Kevin Gimpel. 2016. [通过高斯误差线性单元桥接非线性和随机正则化器](#)。 *CoRR*, abs/1606.08415。

Felix Hill, Kyunghyun Cho, and Anna Korhonen. 2016. 从无标签数据中学习句子的分布式表示。收录于 *2016年北美计算语言学协会：人类语言技术会议论文集*。计算语言学协会。

杰里米·霍华德和塞巴斯蒂安·鲁德。2018。 [用于文本分类的通用语言模型微调](#)。收录于《*ACL*》。计算语言学协会。

Minghao Hu, Yuxing Peng, Zhen Huang, Xipeng Qiu, Furu Wei, 和 Ming Zhou. 2018. 用于机器阅读理解的强化记忆阅读器。收录于 *IJCAI*。

Yacine Jernite, Samuel R. Bowman, and David Sontag. 2017. [基于话语的目标用于快速无监督句子表示学习](#)。 *CoRR*, abs/1705.00557。

Mandar Joshi, Eunsol Choi, Daniel S Weld, and Luke Zettlemoyer. 2017. Triviaqa: A large scale distantly supervised challenge dataset for reading comprehension. In *ACL*.

Ryan Kiros, Yukun Zhu, Ruslan R Salakhutdinov, Richard Zemel, Raquel Urtasun, Antonio Torralba, and Sanja Fidler. 2015. 跳跃思维向量。收录于《神经信息处理系统进展》，第3294–3302页。

Quoc Le 和 Tomas Mikolov. 2014. 句子和文档的分布式表示。收录于《国际机器学习会议》，第1188–1196页。

Hector J Levesque, Ernest Davis, and Leora Morgenstern. 2011. The winograd schema challenge. In *AAAI spring symposium: Logical formalizations of commonsense reasoning*, volume 46, page 47.
Lajanugen Logeswaran 和 Honglak Lee. 2018. 一种高效的句子表示学习框架。收录于《国际学习表示会议》。

Bryan McCann, James Bradbury, Caiming Xiong, and Richard Socher. 2017. Learned in translation: Contextualized word vectors. In *NIPS*.
Oren Melamud, Jacob Goldberger, and Ido Dagan. 2016. context2vec: Learning generic context embedding with bidirectional LSTM. In *CoNLL*.
Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S Corrado, and Jeff Dean. 2013. 词与短语的分布式表示及其组合性。收录于 *Advances in Neural Information Processing Systems 26*, 第3111–3119页。Curran Associates, Inc.

Andriy Mnih 和 Geoffrey E Hinton. 2009年. 一种可扩展的分层分布式语言模型。收录于 D. Koller、D. Schuurmans、Y. Bengio 和 L. Bottou 编，《神经信息处理系统进展21》，第1081–1088页。Curran Associates, Inc.

Ankur P Parikh, Oscar Tackstrom, Dipanjan Das, and Jakob Uszkoreit. 2016. 一种用于自然语言推理的可分解注意力模型。载于 *EMNLP*.
杰弗里·彭宁顿、理查德·索彻和克里斯托弗·D·曼宁。2014年. *Glove: 用于词表示的全局向量*。收录于《自然语言处理经验方法 (EMNLP)》，第1532–1543页。

马修·彼得斯、瓦利德·阿马尔、钱德拉·巴加瓦图拉和拉塞尔·鲍尔。2017. 使用双向语言模型的半监督序列标注。收录于《*ACL*》。

Matthew Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, and Luke Zettlemoyer. 2018a. 深度上下文词表示。载于 *NAACL*。

Matthew Peters, Mark Neumann, Luke Zettlemoyer, 和 Wen-tau Yih. 2018b. 剖析上下文词嵌入：架构与表示。收录于 *2018年自然语言处理经验方法会议论文集*，第1499–1509页。

Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. 2018. 通过无监督学习提升语言理解。技术报告, OpenAI。

Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. 2016. Squad: 100,000+ questions for machine comprehension of text. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pages 2383–2392.
Minjoon Seo, Aniruddha Kembhavi, Ali Farhadi, 和 Hannaneh Hajishirzi. 2017. 用于机器理解的双向注意力流。收录于 *ICLR*.
理查德·索彻、亚历克斯·佩雷林、简·吴、杰森·庄、克里斯托弗·D·曼宁、吴恩达和克里斯托弗·波茨。2013. 用于情感树库语义组合性的递归深度模型。载于《2013年自然语言处理经验方法会议论文集》，第1631–1642页。

Fu Sun, Linyang Li, Xipeng Qiu, and Yang Liu. 2018. U-net: Machine reading comprehension with unanswerable questions. *arXiv preprint arXiv:1810.06638*.

威尔逊·L·泰勒。1953. 完形测试：一种衡量可读性的新工具。《新闻学简报》，30(4):415–433。

Erik F Tjong Kim Sang 和 Fien De Meulder. 2003. conll-2003 共享任务简介：语言无关的命名实体识别。收录于 *CoNLL*。

约瑟夫·图里安、列夫·拉蒂诺夫和约书亚·本希奥。2010. 词表示：一种简单通用的半监督学习方法。收录于《第48届计算语言学协会年会论文集》，*ACL ’10*，第384–394页。

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, 和 Illia Polosukhin. 2017. Attention is all you need. 收录于 *Advances in Neural Information Processing Systems*, 第6000–6010页。

Pascal Vincent, Hugo Larochelle, Yoshua Bengio, and Pierre-Antoine Manzagol. 2008. 使用去噪自编码器提取和组合鲁棒特征。收录于《第25届国际机器学习会议论文集》，第1096–1103页。ACM。

Alex Wang, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, 和 Samuel Bowman. 2018a. Glue: 一个多任务基准测试和分析平台

用于自然语言理解。在《2018年EMNLP黑盒NLP研讨会论文集：分析与解释用于自然语言处理的神经网络》第353–355页。

Wei Wang, Ming Yan, and Chen Wu. 2018b. 用于阅读理解和问答的多粒度层次注意力融合网络。收录于《第56届计算语言学协会年会论文集（第1卷：长篇论文）》。计算语言学协会。

Alex Warstadt, Amanpreet Singh, 和 Samuel R Bowman. 2018. 神经网络可接受性判断. *arXiv 预印本 arXiv:1805.12471*.

Adina Williams, Nikita Nangia, 和 Samuel R Bowman. 2018. 用于通过推理实现句子理解的广泛覆盖挑战语料库。收录于 *NAACL*。

Yonghui Wu, Mike Schuster, Zhifeng Chen, Quoc V Le, Mohammad Norouzi, Wolfgang Macherey, Maxim Krikun, Yuan Cao, Qin Gao, Klaus Macherey, 等。2016. 谷歌神经机器翻译系统：弥合人类与机器翻译之间的差距。 *arXiv 预印本 arXiv:1609.08144*.

Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. 2014. 深度神经网络中的特征可迁移性如何？收录于《神经信息处理系统进展》，第3320–3328页。

Adams Wei Yu, David Dohan, Minh-Thang Luong, Rui Zhao, Kai Chen, Mohammad Norouzi, 和 Quoc V Le. 2018. QANet: 将局部卷积与全局自注意力结合用于阅读理解。收录于 *ICLR*。

Rowan Zellers, Yonatan Bisk, Roy Schwartz, and Yejin Choi. 2018. Swag: A large-scale adversarial dataset for grounded commonsense inference. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Yukun Zhu, Ryan Kiros, Rich Zemel, Ruslan Salakhutdinov, Raquel Urtasun, Antonio Torralba, 和 Sanja Fidler. 2015. 对齐书籍与电影：通过观看电影和阅读书籍实现类故事的视觉解释。收录于《IEEE国际计算机视觉会议论文集》，第19–27页。

“BERT：用于语言理解的深度双向Transformer预训练”附录

我们将附录分为三个部分：

- BERT的额外实现细节见附录 A；

- 我们实验的更多细节见附录 B；以及
- 额外的消融实验在附录 C 中展示。

我们为BERT提供了额外的消融研究，包括：

- 训练步数的影响；以及
- 不同掩码过程的消融实验。

A BERT的补充细节

A.1 预训练任务示意图

我们在下文中提供了预训练任务的示例。

掩码语言模型与掩码过程 假设未标记的句子是 my dog is hairy，并且在随机掩码过程中我们选择了第4个标记（对应于 hairy），我们的掩码过程可以进一步通过以下方式说明

- 80% 的时间：将单词替换为 [MASK] 标记，例如：my dog is hairy → my dog is [MASK]
- 10% 的时间：将单词替换为随机单词，例如：my dog is hairy → my dog is apple
- 10% 的时间：保持单词不变，例如，my dog is hairy → my dog is hairy。这样做的目的是使表示向实际观察到的单词倾斜。

该程序的优势在于Transformer编码器不知道它将被要求预测哪些词，也不知道哪些词已被随机词替换，因此它被迫保留每个输入标记的分布上下文表示。此外，由于随机替换仅发生在所有标记的1.5%（即15%中的10%）上，这似乎不会损害模型的语言理解能力。在第 C.2节中，我们评估了该程序的影响。

与标准语言模型训练相比，掩码语言模型在每个批次中仅对15%的标记进行预测，这表明模型可能需要更多的预训练步骤。




图3: 预训练模型架构的差异。BERT使用双向Transformer。OpenAI GPT使用从左到右的Transformer。ELMo使用独立训练的从左到右和从右到左的LSTM的拼接来生成下游任务的特征。在这三种模型中，只有BERT的表示在所有层中都同时基于左侧和右侧的上下文。除了架构差异外，BERT和OpenAI GPT是微调方法，而ELMo是基于特征的方法。

收敛。在第C.1节中，我们证明了MLM的收敛速度略慢于从左到右的模型（该模型预测每个标记），但MLM模型的经验性改进远超其增加的训练成本。

下一句预测 下一句预测任务可以通过以下示例来阐述。

```
Input = [CLS] the man went to [MASK] store [SEP]
        he bought a gallon [MASK] milk [SEP]
Label = IsNext

Input = [CLS] the man [MASK] to the store [SEP]
        penguin [MASK] are flight ##less birds [SEP]
Label = NotNext
```

A.2 预训练流程

为了生成每个训练输入序列，我们从语料库中采样两个文本片段，尽管它们通常比单个句子长得多（但也可能更短），我们仍将其称为“句子”。第一个句子接收A嵌入，第二个句子接收B嵌入。50%的情况下，B是紧跟在A之后的实际下一句，50%的情况下它是一个随机句子，这是为了“下一句预测”任务而设计的。它们的采样方式使得组合长度 ≤ 512 个标记。LM掩码在WordPiece分词后应用，掩码率为15%的均匀分布，且不对部分单词片段进行特殊处理。

我们以256个序列的批次大小（256个序列 * 512个标记 = 128,000个标记/批次）进行训练，共1,000,000步，大约相当于40

在33亿词语语料库上进行训练。我们使用Adam优化器，学习率为 $1e-4$ ， $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ ，L2权重衰减为0.01，在前10,000步进行学习率预热，并对学习率进行线性衰减。我们在所有层上使用0.1的丢弃概率。遵循OpenAI GPT的做法，我们使用gelu激活函数（Hendrycks and Gimpel, 2016）而非标准的relu。训练损失是平均掩码语言模型似然与平均下一句预测似然之和。

BERT_{BASE} 的训练是在4个Pod配置的Cloud TPU上进行的（共16个TPU芯片）。¹³ BERT_{LARGE} 的训练是在16个Cloud TPU上进行的（共64个TPU芯片）。每次预训练耗时4天完成。

较长的序列成本不成比例地高，因为注意力机制的计算量与序列长度呈平方关系。为了加速我们实验中的预训练，我们在90%的步骤中以128的序列长度预训练模型。然后，我们在剩余10%的步骤中使用512的序列长度进行训练，以学习位置嵌入。

A.3 微调流程

对于微调，大多数模型超参数与预训练时相同，但批量大小、学习率和训练轮数除外。丢弃概率始终保持在0.1。最优超参数值取决于具体任务，但我们发现以下可能值的范围在所有任务中表现良好：

· 批大小: 16, 32

¹³ <https://cloudplatform.googleblog.com/2018/06/CloudTPU-now-offers-preemptible-pricing-and-global-availability.html>

- **学习率 (Adam)** : 5e-5, 3e-5, 2e-5
- **轮数**: 2, 3, 4

我们还观察到，大型数据集（例如，10万+标注训练样本）对超参数选择的敏感度远低于小型数据集。微调通常非常快，因此对上述参数进行穷举搜索，并选择在开发集上表现最好的模型是合理的。

A.4 BERT、ELMo 和 OpenAI GPT 的比较

这里我们研究了近期流行的表示学习模型之间的差异，包括ELMo、OpenAI GPT和BERT。模型架构之间的比较在图3中以可视化方式展示。请注意，除了架构差异外，BERT和OpenAI GPT是微调方法，而ELMo是基于特征的方法。

与BERT最可比的现有预训练方法是OpenAI GPT，它在大型文本语料库上训练一个从左到右的Transformer语言模型。事实上，BERT中的许多设计决策都是有意为之，使其尽可能接近GPT，以便对这两种方法进行最小程度的比较。本研究的核心论点是，第3.1节中提出的双向性和两个预训练任务构成了经验性改进的主要部分，但我们也注意到BERT和GPT的训练方式之间还存在其他几点差异：

- GPT是在BooksCorpus（8亿词）上训练的；BERT是在BooksCorpus（8亿词）和维基百科（25亿词）上训练的。

- GPT 使用句子分隔符 ([SEP]) 和分类器标记 ([CLS])，这些标记仅在微调阶段引入；BERT 在预训练期间学习 [SEP]、[CLS] 和句子 A/B 嵌入。

- GPT 经过 100 万步训练，批大小为 32,000 个词；BERT 经过 100 万步训练，批大小为 128,000 个词。

- GPT在所有微调实验中使用了相同的5e-5学习率；BERT则选择在验证集上表现最佳的任务特定微调学习率。

为了隔离这些差异的影响，我们在第5.1节中进行了消融实验，实验结果表明，大部分的改进实际上来自于两个预训练任务及其所实现的双向性。

A.5 不同任务微调的示例

在不同任务上微调BERT的图示见图 4。我们的特定任务模型是通过将BERT与一个额外的输出层结合而成的，因此只需要从头学习极少量的参数。在这些任务中，(a)和(b)是序列级任务，而(c)和(d)是标记级任务。在图中，E代表输入嵌入，Ti代表标记i的上下文表示，[CLS]是用于分类输出的特殊符号，[SEP]是用于分隔非连续标记序列的特殊符号。

B 详细实验设置

B.1 GLUE基准实验的详细描述。

我们的GLUE结果在表1中，获取自<https://gluebenchmark.com/排行榜>和<https://blog.openai.com/language-unsupervised>。

GLUE基准测试包含以下数据集，其描述最初总结于Wang等（2018a）：

MNLI 多领域自然语言推理是一项大规模、众包的蕴含分类任务（Williams et al., 2018）。给定一对句子，目标是预测第二句话相对于第一句话是蕴含、矛盾还是中立。

QQP Quora问题对是一个二分类任务，其目标是确定在Quora上提出的两个问题在语义上是否等价（Chen等，2018）。

QNLI 问题自然语言推理是斯坦福问答数据集（Rajpurkar et al., 2016）的一个版本，它已被转换为二分类任务（Wang et al., 2018a）。正样本是包含正确答案的（问题，句子）对，而负样本是来自同一段落但不包含答案的（问题，句子）。




图4：在不同任务上微调BERT的示意图。

SST-2 斯坦福情感树库是一个二分类单句任务，由从电影评论中提取的句子组成，并带有情感的人工标注（Socher 等人，2013）。

CoLA 语言可接受性语料库是一个二元单句分类任务，其目标是预测一个英语句子在语言学上是否“可接受”（Warstadt 等人，2018）。

STS-B 语义文本相似度基准是一个从新闻标题和其他来源中提取的句子对集合（Cer 等人，2017）。它们被标注了1到5的分数，表示两个句子在语义含义上的相似程度。

MRPC 微软研究改写语料库由从在线新闻来源自动提取的句子对组成，并带有人工标注

用于判断这对句子在语义上是否等价（Dolan and Brockett，2005）。

RTE 文本蕴含识别是一项类似于MNLI的二元蕴含任务，但训练数据要少得多（Bentivogli et al., 2009）。¹⁴

WNLI Winograd NLI 是一个小型自然语言推理数据集（Levesque 等人，2011）。GLUE 网页指出该数据集的构建存在问题，¹⁵ 并且所有提交给 GLUE 的训练系统表现都差于预测多数类别的 65.1 基准准确率。因此，为了对 OpenAI GPT 公平起见，我们排除了这个集合。在我们的 GLUE 提交中，我们总是预测 ma-

¹⁴ 请注意，我们在本文中仅报告了单任务微调的结果。多任务微调方法可能会进一步提升性能。例如，我们确实观察到在MNLI上进行多任务训练对RTE有显著的提升。

<https://gluebenchmark.com/faq>

多数类。

C 额外消融实验

C.1 训练步数的影响

图 5 展示了在经过 k 步预训练的检查点上进行微调后的 MNLI Dev 准确率。这使我们能够回答以下问题：

1. 问题：BERT真的需要如此大量的预训练（128,000词/批次 * 1,000,000步）才能达到高微调准确率吗？回答：是的，BERT_{BASE}在1M步训练时相比500k步，在MNLI上几乎提升了1.0%的准确率。
2. 问题：MLM预训练是否比LTR预训练收敛更慢，因为每个批次中只有15%的词被预测，而不是每个词？回答：MLM模型的收敛速度确实比LTR模型稍慢。然而，就绝对准确率而言，MLM模型几乎立即就开始超越LTR模型。

C.2 不同掩码过程的消融实验

在第3.1节中，我们提到BERT在以掩码语言模型（MLM）目标进行预训练时，对目标标记使用混合策略进行掩码。以下是评估不同掩码策略效果的消融研究。




图5：关于训练步数的消融实验。这展示了在经过k步预训练的模型参数基础上进行微调后的MNLI准确率。x轴是k的值。

请注意，掩码策略的目的是减少预训练和微调之间的不匹配，因为[MASK]符号在微调阶段从未出现。我们报告了MNLI和NER的验证集结果。对于NER，我们报告了微调 and 基于特征的方法，因为我们预计基于特征的方法会放大这种不匹配，因为模型将没有机会调整表示。

掩码率		开发集结果		
掩码相同	RND	微调	命名实体识别	
			微调	基于特征的
80%	10%	84.2	95.4	94.9
00%	0%	84.3	94.9	94.0
80%	20%	84.1	95.2	94.6
80%	0%	84.4	95.2	94.7
00%	80%	83.7	94.8	94.6
0%	100%	83.6	94.9	94.6

表8：不同掩码策略的消融实验。

结果如表 8 所示。在表中，MASK 表示我们将目标标记替换为 [MASK] 符号进行 MLM；SAME 表示我们保持目标标记不变；RND 表示我们将目标标记替换为另一个随机标记。

表格左侧的数字代表了在MLM预训练期间所使用的特定策略的概率（BERT使用80%、10%、10%）。论文的右侧部分代表了验证集的结果。对于基于特征的方法，我们将BERT的最后4层拼接作为特征，这在第5.3节中已被证明是最佳方法。

从表中可以看出，微调对不同的掩码策略具有出人意料的鲁棒性。然而，正如预期的那样，在将基于特征的方法应用于命名实体识别时，仅使用掩码策略会产生问题。有趣的是，仅使用随机策略的表现也比我们的策略差得多。