

如何微调BERT进行文本分类?

Chi Sun, Xipeng Qiu^{*}, Yige Xu, Xuanjing Huang

上海市智能信息处理重点实验室, 复旦大学计算机科学学院, 复旦大学,
中国上海张江路825号

{sunc17,xpqiuyg, ygxu18, xjhuang}@fudan.edu.cn

摘要

语言模型预训练已被证明在学习通用语言表示方面非常有用。作为一种最先进的语言模型预训练模型, BERT (来自Transformer的双向编码器表示) 在许多语言理解任务中取得了令人惊叹的成果。在本文中, 我们进行了详尽的实验, 以研究BERT在文本分类任务上的不同微调方法, 并提供了一个通用的解-

tion for BERT fine-tuning. Finally, the proposed solution obtains new state-of-the-art results on eight widely-studied text classification datasets.¹

1 引言

文本分类是自然语言处理 (NLP) 中的一个经典问题。该任务是将预定义的类别分配给给定的文本序列。一个重要的中间步骤是文本表示。以往的工作使用各种神经模型来学习文本表示, 包括卷积模型 (Kalchbrenner et al., 2014; Zhang et al., 2015; Conneau et al., 2016; Johnson and Zhang, 2017; Zhang et al., 2017; Shen et al., 2018), 循环模型 (Liu et al., 2016; Yogatama et al., 2017; Seo et al., 2017), 以及注意力机制 (Yang et al., 2016; Lin et al., 2017)。

或者, 大量研究表明, 在大规模语料库上预训练的模型对文本分类和其他自然语言处理任务有益, 这可以避免从头开始训练新模型。一种预训练模型是词嵌入, 例如word2vec (Mikolov et al., 2013) 和 GloVe (Pennington et al., 2014), 或者是上下文相关的词嵌入, 例如 CoVe (McCann et al., 2017) ELMo (Peters et al.,

2018)。这些词嵌入通常被用作主任务的额外特征。另一种预训练模型是句子级别的。Howard 和 Ruder (2018) 提出了 ULMFiT, 这是一种针对预训练语言模型的微调方法, 在六个广泛研究的文本分类数据集上取得了最先进的结果。最近, 预训练语言模型已被证明在利用大量无标签数据学习通用语言表示方面非常有用: 例如, OpenAI GPT (Radford 等人, 2018) 和 BERT (Devlin 等人, 2018)。BERT 基于多层双向 Transformer (Vaswani 等人, 2017), 并在纯文本上进行训练, 用于掩码词预测和下一句预-词典任务。

尽管BERT在许多自然语言理解 (NLU) 任务中取得了惊人的成果, 但其潜力尚未得到充分挖掘。目前很少有研究通过增强BERT来进一步提升其在目标任务上的性能。

在本文中, 我们研究如何最大化BERT在文本分类任务中的利用率。我们探索了微调BERT的几种方法, 以提升其在文本分类任务上的性能。我们设计了详尽的实验, 对BERT进行了深入分析。

我们论文的贡献如下:

- 我们提出了一种微调预训练BERT模型的通用方案, 包括三个步骤: (1) 在任务内训练数据或领域内数据上进一步预训练BERT; (2) 如果有多个相关任务可用, 则可选地使用多任务学习微调BERT; (3) 为目标任务微调BERT。

- 我们还研究了针对目标任务的BERT微调方法, 包括长文本预处理、层选择、逐层学习率、灾难性遗忘,

^{*}通讯作者

¹源代码可在 <https://github.com/xuyige/BERT4doc-Classification> 获取。

以及少样本学习问题。

· 我们在七个广泛研究的英文文本分类数据集和一个中文新闻分类数据集上实现了新的最先进结果。

2 相关工作

从其他任务中借鉴已学知识在自然语言处理领域正受到越来越多的关注。我们简要回顾两种相关方法：语言模型预训练和多任务学习。

2.1 语言模型预训练

预训练词嵌入 (Mikolov et al., 2013; Pennington et al., 2014) 作为现代自然语言处理系统的重要组成部分，相比从零开始学习的嵌入可以提供显著的改进。词嵌入的泛化形式，例如句子嵌入 (Kiros et al., 2015; Logeswaran and Lee, 2018) 或段落嵌入 (Le and Mikolov, 2014)，也被用作下游模型中的特征。

Peters等人 (2018) 将源自语言模型的嵌入作为额外特征拼接至主任务中，并刷新了多个主要自然语言处理基准测试的最先进水平。除了使用无监督数据进行预训练外，使用大量有监督数据进行迁移学习也能取得良好性能，例如自然语言推理 (Conneau等人, 2017) 和机器翻译 (McCann等人, 2017)。

最近，在包含大量无标签数据的大型网络上预训练语言模型，并在下游任务中进行微调的方法，在多个自然语言理解任务中取得了突破，例如OpenAI GPT (Radford et al., 2018) 和 BERT (Devlin et al., 2018)。Dai and Le (2015) 使用了语言模型微调，但在1万个有标签样本上出现了过拟合，而Howard and Ruder (2018) 提出了ULMFiT并实现了最先进的重-

在文本分类任务中。BERT通过大规模跨领域语料库在掩码语言模型任务和下一句预测任务上进行预训练。与以往仅限于两个单向语言模型组合（即从左到

右和从右到左），BERT使用一种掩码语言模型来预测被随机掩码或替换的词。BERT是第一个基于微调的表示模型，实现了最先进的

一系列NLP任务的最优结果，展示了微调方法的巨大潜力。在本文中，我们进一步探索了用于文本分类的BERT微调方法。

2.2 多任务学习

多任务学习 (Caruana, 1993; Collobert and Weston, 2008) 是另一个相关的方向。Rei (2017) 和Liu et al. (2018) 使用这种方法来联合训练语言模型和主任务模型。Liu et al. (2019) 通过将BERT作为其共享文本编码层，扩展了Liu et al. (2015) 最初提出的MT-DNN模型。MTL每次都需要从头开始训练任务，这使得它效率低下，并且通常需要仔细权衡特定任务的目标函数 (Chen et al., 2017)。然而，我们可以通过充分利用共享的预训练模型，使用多任务BERT微调来避免这个问题。

3 用于文本分类的BERT

BERT-base模型包含一个编码器，具有12个Transformer块、12个自注意力头以及768的隐藏层大小。BERT接收不超过512个标记的序列作为输入，并输出该序列的表示。该序列包含一个或两个分段，序列的第一个标记始终是[CLS]，它包含特殊的分类嵌入，而另一个特殊标记[SEP]用于分隔分段。

对于文本分类任务，BERT将第一个标记[CLS]的最终隐藏状态 h 作为整个序列的表示。在BERT的顶部添加一个简单的softmax分类器，以预测标签 c 的概率：

$$p(c|h) = \text{softmax}(Wh), \quad (1)$$

其中 W 是特定任务的参数矩阵。我们通过最大化正确标签的对数概率，联合微调BERT的所有参数以及 W 。

4 方法论

当我们把BERT适配到目标领域的NLP任务时，需要一个合适的微调策略。在本文中，我们从以下三个方面寻找合适的微调方法。




图1: 微调BERT的三种通用方法, 以不同颜色表示。

1) **微调策略**: 当我们为目标任务微调BERT时, 有多种利用BERT的方法。例如, BERT的不同层捕捉不同层级的语义和句法信息, 哪一层更适合目标任务? 我们如何选择更好的优化算法和学习率? 2) **进一步预训练**: BERT是在通用领域训练的, 其数据分布与目标领域不同。一个自然的想法是用目标领域数据对BERT进行进一步预训练。

3) **多任务微调**: 在没有预训练语言模型的情况下, 多任务学习已证明其在利用多个任务间共享知识方面的有效性。当目标领域存在多个可用任务时, 一个有趣的问题是, 同时所有任务上微调BERT是否仍能带来收益。

我们微调BERT的通用方法如图1所示。

4.1 微调策略

神经网络的不同层可以捕捉不同层级的句法和语义信息 (Yosinski et al., 2014; Howard and Ruder, 2018)。

为了将BERT适配到目标任务, 我们需要考虑几个因素: 1) 第一个因素是长文本的预处理, 因为BERT的最大序列长度为512。2) 第二个因素是层选择。官方的BERT-base模型由一个嵌入层、一个12层编码器和一个池化层组成。我们需要为文本分类任务选择最有效的层。3) 第三个因素是过拟合问题。需要一个带有合适学习率的更好优化器。

直观上, BERT模型的较低层可能包含更通用的信息。我们可以使用不同的学习率对它们进行微调。

遵循Howard和Ruder (2018), 我们将参数 θ 划分为 $\{\theta^1, \dots, \theta^L\}$, 其中 θ^1 包含

保留BERT第1层的参数。然后参数按如下方式更新:

$$\theta_t^l = \theta_{t-1}^l - \eta^l \cdot \nabla_{\theta^l} J(\theta), \quad (2)$$

其中 η^l 表示第 l 层的学习率。

我们将基础学习率设置为 η^L , 并使用 $\eta^{k-1} = \xi \cdot \eta^k$, 其中 ξ 是衰减因子且小于或等于1。当 $\xi < 1$ 时, 较低层的学习率低于较高层。当 $\xi = 1$ 时, 所有层的学习率相同, 这等同于常规的随机梯度下降 (SGD)。我们将在第5.3节中探讨这些因素。

4.2 进一步预训练

BERT模型在通用领域语料库上进行预训练。对于特定领域 (如电影评论) 的文本分类任务, 其数据分布可能与BERT不同。因此, 我们可以在特定领域数据上, 通过掩码语言模型和下一句预测任务对BERT进行进一步预训练。执行了三种进一步的预训练方法:

1) 任务内预训练, 即在目标任务的训练数据上对BERT进行进一步预训练。

2) 域内预训练, 其中预训练数据获取自目标任务的相同领域。例如, 存在若干不同的情感分类任务, 它们具有相似的数据分布。我们可以进一步在这些任务的组合训练数据上对BERT进行预训练。

3) 跨域预训练, 其中预训练数据既来自与目标任务相同的领域, 也来自其他不同领域。我们将在第5.4节中探讨这些不同的进一步预训练方法。

4.3 多任务微调

多任务学习也是一种有效的方法, 用于共享从多个相关监督任务中获得的知识。与Liu等人 (2019) 类似, 我们也使用多任务学习框架微调BERT进行文本分类。

所有任务共享BERT层和嵌入层。唯一不共享的层是最终的分类层, 这意味着每个任务都有一个私有的分类器层。实验分析在第5.5节中。

数据集	类别	类型	长度	最大值	超过	训练	测试
IMDb	2	情感	292	3,045	12.69%	25,000	25,000
Yelp P.	2	情感	177	2,066	4.60%	560,000	38,000
Yelp C.	5	情感	179	3,842	0.60%	550,000	50,000
TREC	6	Question	11	39	0.00%	5,452	500
雅虎问答	10	问题	131	4,018	2.65%	1,400,000	60,000
AG新闻	4	主题	44	221	0.00%	120,000	7,600
搜狗新闻	14	主题	637	37,988	0.00%	540,000	60,000
Sogou News	6	Topic	737	47,988	46.23%	54,000	6,000

表 1: 八个文本分类数据集的统计数据。超过比例是指长度超过 512 的样本数量百分比。

5 实验

我们研究了针对七个英文和两个中文文本分类任务的不同微调方法。我们分别使用了基础BERT模型：uncased BERT-base模型²和中文BERTbase模型³。

5.1 数据集

我们在八个广泛研究的数据集上评估了我们的方法。这些数据集具有不同数量的文档和不同的文档长度，涵盖了三个常见的文本分类任务：情感分析、问题分类和主题分类。我们在表 1 中展示了每个数据集的统计数据。

情感分析 对于情感分析，我们使用二分类电影评论IMDb数据集（Maas et al., 2011）以及由Zhang et al. (2015) 构建的Yelp评论数据集的二分类和五分类版本。

问题分类 对于问题分类，我们在六分类版本的TREC数据集（Voorhees and Tice, 1999）和由Zhang et al. (2015) 创建的Yahoo! Answers数据集上评估我们的方法。TREC数据集是用于问题分类的数据集，由分为广泛语义类别的开放领域、基于事实的问题组成。与其他文档级数据集相比，TREC数据集是句子级的，且其训练样本较少。Yahoo! Answers数据集是一个包含1,400k训练样本的大型数据集。

主题分类 对于主题分类，我们使用由Zhang等 (2015) 创建的大规模AG's News和DBPedia。为了测试ef-

为了评估BERT在中文文本上的有效性，我们创建了搜狗新闻语料库的中文训练和测试数据集。与Zhang等 (2015) 不同，我们直接使用汉字而非拼音。该数据集是搜狗CA和搜狗CS新闻语料库的结合体（Wang等, 2008）。我们根据URL确定新闻类别，例如“体育”对应“http://sports.sohu.com”。我们选择了6个类别——“体育”、“房产”、“财经”、“娱乐”、“女性”和“科技”。每个类别选择的训练样本数量为9,000个，测试样本数量为1,000个。

数据预处理 遵循Devlin等 (2018)，我们使用WordPiece嵌入（Wu等, 2016），词表大小为30,000个标记，并用##表示分割的词块。因此，数据集中的文档长度统计是基于这些词块的。为了进行BERT的进一步预训练，我们使用spaCy⁴对英文数据集进行句子分割，而在处理中文搜狗新闻数据集时，我们使用“。”、“？”和“！”作为分隔符。

5.2 超参数

我们使用BERT-base模型（Devlin et al., 2018），其隐藏层大小为768，包含12个Transformer块（Vaswani et al., 2017）和12个自注意力头。我们进一步在1块TITAN Xp GPU上使用BERT进行预训练，批大小为32，最大序列长度为128，学习率为5e-5，训练步数为100,000，预热步数为10,000。

我们在4块TITAN Xp GPU上微调BERT模型，并将批大小设置为24，以确保GPU显存得到充分利用。Dropout概率始终保持在0.1。我们使用Adam优化器，其中 $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ 。我们使用倾斜三角形学习率（Howard and Ruder, 2018），该

²https://storage.googleapis.com/bert_models/2018_10_18/uncased_L-12_H-768_A-12.zip

³https://storage.googleapis.com/bert_models/2018_11_03/chinese_L-12_H-768_A-12.zip

⁴<https://spacy.io/>

基础学习率为2e-5，预热比例为0.1。我们根据经验将最大轮数为4，并保存验证集上的最佳模型用于测试。

5.3 实验一：研究不同的微调策略

在本小节中，我们使用IMDb数据集来研究不同的微调策略。官方预训练模型被设置为初始编码器⁵。

5.3.1 处理长文本

BERT的最大序列长度为512。将BERT应用于文本分类时的第一个问题是如何处理长度超过512的文本。我们尝试以下方法来处理长文章。

截断方法 通常，文章的关键信息位于开头和结尾。我们使用三种不同的文本截断方法来进行BERT微调。

1. **仅保留头部**: 保留前510个标记⁶；
2. **仅尾部**: 保留最后 510 个 token；
3. **头+尾**: 经验性地选择前128个和最后382个标记。

分层方法 输入文本首先被划分为 $k = L/510$ 个片段，这些片段被输入到 BERT 中以获取这 k 个文本片段的表示。每个片段的表示是最后一层 [CLS] 标记的隐藏状态。然后我们使用平均池化、最大池化和自注意力机制来组合所有片段的表示。

表 2 展示了上述方法的有效性。**头+尾**截断方法在IMDb和Sogou数据集上取得了最佳性能。因此，我们在后续实验中使用该方法来处理长文本。

5.3.2 来自不同层的特征

BERT的每一层都捕捉输入文本的不同特征。我们研究了来自不同层的特征的有效性。然后我们微调模型，并记录测试错误率上的性能。

表 3 展示了使用不同层微调 BERT 的性能。来自的特征

⁵ <https://github.com/google-research/bert>
⁶ 512 以减去 [CLS] 和 [SEP] 标记。

方法	IMDb	搜狗
仅头部	5.63	2.58
仅尾部	5.44	3.17
头+尾	5.42	2.43
层级. 平均值	5.89	2.83
hier. max	5.71	2.47
层. 自注意力	5.49	2.65

表 2: IMDb 和中文搜狗新闻数据集上的测试错误率 (%)。

BERT的最后一层表现最好。因此，我们在后续实验中采用这一设置。

层	测试错误率(%)
第0层	11.07
第一层	9.81
第二层	9.29
第三层	8.66
第四层	7.83
第五层	6.83
第六层	6.41
第七层	6.41
Layer-7	6.41
第8层	6.04
第9层	5.70
第10层	5.46
第11层	5.42
前4层 + 拼接	8.69
前4层 + 平均值	9.09
前4层 + 最大值	8.76
最后4层 + 拼接	5.43
最后4层 + 最大值	5.42
Last 4 Layers + max	5.42
所有12层 + 拼接	5.44

表3: 在IMDb数据集上使用不同层微调BERT。

5.3.3 灾难性遗忘

灾难性遗忘 (McCloskey and Cohen, 1989) 通常是迁移学习中的一个常见问题，这意味着预训练的知识在学习新知识的过程中被抹除。因此，我们还调查了BERT是否也存在灾难性遗忘问题。

我们使用不同的学习率对BERT进行微调，在IMDb上的错误率学习曲线如图2所示。

我们发现，较低的学习率（例如 2e-5）对于使 BERT 克服灾难性遗忘问题是必要的。使用 4e-4 这种激进的学习率时，训练集无法收敛。




图2：灾难性遗忘

5.3.4 逐层递减层速率

表 4 展示了不同基础学习率和衰减因子（见公式 (2)）在 IMDB 数据集。我们发现为较低层分配较低的学习率对于微调BERT是有效的，一个合适的设置是 $\xi=0.95$ 和 $lr=2.0e-5$ 。

学习率	衰减因子 ξ	测试错误率(%)
2.5e-5	1.00	5.52
2.5e-5	0.95	5.46
2.5e-5	0.90	5.44
2.5e-5	0.85	5.58
2.0e-5	1.00	5.42
2.0e-5	0.95	5.40
2.0e-5	0.90	5.52
2.0e-5	0.85	5.65

表4：逐层递减的层速率。

5.4 Exp-II：进一步预训练的调查

此外，除了使用监督学习微调BERT，我们还可以通过无监督的掩码语言模型和下一句预测任务，在训练数据上进一步预训练BERT。在本节中，我们研究进一步预训练的有效性。在接下来的实验中，我们在微调阶段使用实验I中的最佳策略。

5.4.1 任务内进一步预训练

因此，我们首先研究任务内进一步预训练的有效性。我们采用不同步数的进一步预训练模型，然后使用文本分类任务对其进行微调。

如图3所示，进一步的预训练有助于提高BERT在目标任务上的性能，在100K训练步数后达到了最佳性能。




图3：不同进一步预训练步骤在IMDb数据集上的收益。BERT-ITPT-FIT表示“BERT + 任务内预训练 + 微调”。

5.4.2 域内与跨域进一步预训练

除了目标任务的训练数据外，我们还可以在相同领域的数据上进一步预训练BERT。在本小节中，我们研究使用领域内和跨领域数据进一步预训练BERT是否能继续提升BERT的性能。

我们将七个英文数据集划分为三个领域：主题、情感和问题。这种划分方式并非完全准确。因此，我们还进行了广泛的跨任务预训练实验，其中每个任务都被视为一个不同的领域。

结果如表5所示。我们发现，几乎所有进一步预训练模型在所有七个数据集上的表现都优于原始的BERTbase模型（表5中的“w/o pretrain”行）。通常，域内预训练比任务内预训练能带来更好的性能。在小型句子级TREC数据集上，任务内预训练会损害性能，而利用Yah. A.语料库的域内预训练在TREC上能取得更好的结果。

跨域预训练（表 5 中的“all”行）

数据集	情感			问题		主题	
	IMDb	Yelp P.	Yelp F.	TREC	Yah. A.	AG的新闻	DBPedia
IMDb	4.37	2.18	29.60	2.60	22.39	5.24	0.68
Yelp P.	5.24	1.92	29.32	2.00	22.38	5.43	0.65
Yelp F.	5.18	1.94	29.42	2.40	22.33	5.43	0.65
所有情感	4.88	1.87	29.25	3.00	22.35	5.34	0.67
所有问题	5.65	2.09	29.35	3.20	22.17	5.12	0.66
	5.52	2.08	29.31	1.80	22.38	5.16	0.67
	5.68	2.14	29.52	2.20	21.86	5.21	0.68
所有主题	5.97	2.15	29.38	2.00	22.32	4.80	0.68
	5.80	2.13	29.47	2.60	22.30	5.13	0.68
	5.85	2.20	29.68	2.60	22.28	4.88	0.65
全部	5.18	1.97	29.20	2.80	21.94	5.08	0.67
无预训练	5.40	2.28	30.06	2.80	22.42	5.25	0.71

表 5：在七个数据集上进行域内和跨域进一步预训练的性能。每个数据集均进一步预训练了 100k 步。第一列表示不同的进一步预训练数据集。“all sentiment”表示该数据集包含情感领域的所有训练数据集。“all”表示该数据集包含所有七个训练数据集。请注意，Yelp P. 和 Yelp F. 中的部分数据存在重叠，例如，Yelp P. 测试集中的部分数据会出现在 Yelp F. 的训练集中，因此我们在进一步预训练期间从训练集中移除了这部分数据。

通常不会带来明显的收益。这是合理的，因为 BERT 已经在通用领域上进行了训练。

我们还发现 IMDb 和 Yelp 在情感领域互不帮助。原因可能是 IMDb 和 Yelp 是电影和食物这两个不同的情感任务。数据分布存在显著差异。

5.4.3 与以往模型的比较

我们将我们的模型与以下多种不同方法进行比较：基于 CNN 的方法，如 Char-level CNN (Zhang et al., 2015)、VDCNN (Conneau et al., 2016) 和 DPCNN (Johnson and Zhang, 2017)；基于 RNN 的模型，如 D-LSTM (Yogatama et al., 2017)、Skim-LSTM (Seo et al., 2017) 和分层注意力网络 (Yang et al., 2016)；基于特征的迁移学习方法，如 region embedding (Qiao et al., 2018) 和 CoVe (McCann et al., 2017)；以及语言模型微调方法 (ULMFiT) (Howard and Ruder, 2018)，这是目前文本分类领域的最先进方法。

我们通过使用 BERT 模型的特征作为带有自注意力机制的 biLSTM 的输入嵌入来实现 BERT-Feat (Lin et al., 2017)。BERT-IDPT-FiT 的结果对应于表 5 中 “all sentiment”、“all question” 和 “all topic” 所在的行，而 BERT-CDPTFiT 的结果则对应于其中的 “all” 行。

如表 6 所示，BERT-Feat 表现出

优于除 ULMFiT 以外的所有其他基准模型。

除了在 DBpedia 数据集上略逊于 BERTFeat 外，BERT-FiT 在其他七个数据集上均优于 BERT-Feat。此外，所有三个进一步预训练模型都优于 BERT-FiT 模型。以 BERT-Feat 为参考，我们计算了其他 BERT-FiT 模型在每个数据集上的平均百分比提升。BERT-IDPT-FiT 表现最佳，平均错误率降低了 18.57%。

5.5 实验-III：多任务微调

当存在多个文本分类任务的数据集时，为了充分利用这些可用数据，我们进一步考虑了带有多任务学习的微调步骤。我们使用了四个英文文本分类数据集 (IMDb、Yelp P.、AG 和 DBP)。数据集 Yelp F. 被排除在外，因为 Yelp F. 的测试集与 Yelp P. 的训练集之间存在重叠，另外两个问题领域的数据集也被排除在外。

我们分别使用官方的 uncased BERTbase 权重以及在所有七个英语分类数据集上进一步预训练的权重进行实验。为了在每个子任务上获得更好的分类结果，在共同微调之后，我们使用较低的学习率在各自的数据集上进行额外的微调步骤。

表 7 显示，基于 BERT 的多任务微调效果有所提升。然而，多任务微调似乎并没有帮助-

模型	IMDb	Yelp P.	Yelp F.	TREC	Yah. A.	AG	DBP	搜狗	平均值 Δ
字符级CNN(Zhang等, 2015)	/	4.88	37.95	/	28.80	9.51	1.55	3.80	/
VDCNN (Conneau 等人, 2016)	/	4.28	35.28	/	26.57	8.67	1.29	3.28	/
DPCNN (Johnson and Zhang, 2017)	/	2.64	30.58	/	23.90	6.87	0.88	3.48	/
D-LSTM (Yogatama 等人, 2017)	/	7.40	40.40	/	26.30	7.90	1.30	5.10	/
标准LSTM (Seo等, 2017)	8.90	/	/	/	/	6.50	/	/	/
Skim-LSTM (Seo et al., 2017)	8.80	/	/	/	/	6.40	/	/	/
HAN (Yang et al., 2016)	/	/	/	/	24.20	/	/	/	/
区域嵌入 (Qiao 等人, 2018)	/	3.60	35.10	/	26.30	7.20	1.10	2.40	/
CoVe (McCann et al., 2017)	8.20	/	/	4.20	/	/	/	/	/
ULMFiT (Howard and Ruder, 2018)	4.60	2.16	29.98	3.60	/	5.01	0.80	/	/
BERT-Feat	6.79	2.39	30.47	4.20	22.72	5.92	0.70	2.50	-
BERT-FiT	5.40	2.28	30.06	2.80	22.42	5.25	0.71	2.43	9.22%
BERT-ITPT-FiT	4.37	1.92	29.42	3.20	22.38	4.80	0.68	1.93	16.07%
BERT-IDPT-FiT	4.88	1.87	29.25	2.20	21.86	4.88	0.65	/	18.57%
BERT-CDPT-FiT	5.18	1.97	29.20	2.80	21.94	5.08	0.67	/	14.38%

表 6: 八个文本分类数据集上的测试错误率 (%)。不带 的先前模型结果是其论文中报告的结果。/ 表示未报告。表示结果来自我们的实现，因为搜狗数据集与他们的不同。BERT-Feat 表示“BERT 作为特征”。BERT-FiT 表示“BERT + 微调”。BERT-ITPT-FiT 表示“BERT + 任务内预训练 + 微调”。BERT-IDPT-FiT 表示“BERT + 领域内预训练 + 微调”。BERT-CDPT-FiT 表示“BERT + 跨领域预训练 + 微调”。

方法	IMDb	Yelp P.	AG	DBP
BERT-FiT	5.40	2.28	5.25	0.71
BERT-MFiT-FiT	5.36	2.19	5.20	0.68
BERT-CDPT-FiT	5.18	1.97	5.08	0.67
BERT-CDPT-MFiT-FiT	4.96	2.06	5.13	0.67

表 7: 多任务微调下的测试错误率 (%)。

在 Yelp P. 和 AG. 上对 BERT-CDPT 而言。多任务微调 and 跨域预训练可能是替代方法，因为 BERT-CDPT 模型已经包含了丰富的特定领域信息，并且多任务学习可能对于提高相关文本分类子任务的泛化能力并非必要。

5.6 Exp-IV: 少样本学习

预训练模型的一个优势是能够在较小的训练数据下训练出适用于下游任务的模型。我们在不同数量的训练样本上评估了 BERT-FiT 和 BERT-ITPT-FiT。我们选取了 IMDb 训练数据的一个子集，并将其输入到 BERT-FiT 和 BERT-ITPT-FiT 中。我们在图 4 中展示了结果。

该实验结果表明，BERT 对小规模数据带来了显著的提升。进一步预训练的 BERT 可以进一步提升其性能，使错误率从 17.26% 降低至 9.23%，仅需

0.4% 训练数据。




图4: 在不同比例训练样本下IMDb数据集上的测试错误率(%)。

5.7 Exp-V: 在 BERT Large 上进行进一步预训练

在本小节中，我们研究 BERT_{LARGE} 模型是否具有与 BERT_{BASE} 相似的发现。我们进一步在 1 块 Tesla-V100 PCIE 32G GPU 上预训练 Google 的预训练 BERT_{LARGE} 模型⁷，批大小为 24，最大序列长度为 128，训练步数为 120K。对于目标任务分类器 BERT 微调，我们将批大小设置为 24，并在 4 块 Tesla-V100-PCIE 32G GPU 上微调 BERT_{LARGE}，最大序列长度为 512。

⁷https://storage.googleapis.com/bert_models/2018_10_18/uncased_L-24_H-1024_A-16.zip

如表8所示，与BERTBASE相比，ULMFiT在几乎所有任务上的表现都更好，但与BERTLARGE相比则不然。然而，随着针对特定任务的进一步预训练，情况发生了变化，甚至BERT_{BASE}在所有任务上都优于ULMFiT。结合针对特定任务的进一步预训练，BERT_{LARGE} 微调实现了最先进的结果。

模型	IMDb	Yelp P.	Yelp F.	AG	DBP
ULMFiT	4.60	2.16	29.98	5.01	0.80
BERTBASE	5.30	2.28	29.08	5.88	0.78
+ ITPT	4.37	1.92	29.42	4.80	0.68
BERTLARGE	4.86	1.84	28.82	4.86	0.62
+ ITPT	4.21	1.81	28.62	4.66	0.61

表 8：五个文本分类数据集上的测试错误率 (%)。

6 结论

在本文中，我们进行了广泛的实验，以研究针对文本分类任务微调BERT的不同方法。有一些实验发现：1) BERT的顶层对文本分类更有用；2) 采用适当的逐层递减学习率，BERT可以克服灾难性遗忘问题；3) 任务内和领域内的进一步预训练可以显著提升其性能；4) 前置的多任务微调也有助于单任务微调，但其收益小于进一步预训练；5) BERT可以在小规模数据上提升任务性能。

凭借上述发现，我们在八个广泛研究的文本分类数据集上实现了最先进的性能。未来，我们将进一步探索BERT的工作原理。

参考文献

Rich Caruana. 1993. 多任务学习：一种基于知识的归纳偏置来源。收录于《第十届国际机器学习会议论文集》。

赵晨, Vijay Badrinarayanan, Chen-Yu Lee, 和 Andrew Rabinovich. 2017. Gradnorm：深度多任务网络中用于自适应损失平衡的梯度归一化。arXiv 预印本 arXiv:1711.02257。

Ronan Collobert 和 Jason Weston. 2008. 一种用于自然语言处理的统一架构：具有多任务学习的深度神经网络。收录于《第25届国际机器学习会议论文集》，第160–167页。ACM。

Alexis Conneau, Douwe Kiela, Holger Schwenk, Loic Barrault, 和 Antoine Bordes. 2017. 从自然语言推理数据中监督学习通用句子表示。arXiv 预印本 arXiv:1705.02364。

Alexis Conneau, Holger Schwenk, Loic Barrault, 和 Yann Lecun. 2016. 用于自然语言处理的极深卷积网络。arXiv preprint arXiv:1606.01781, 2.

Andrew M Dai 和 Quoc V Le. 2015. 半监督序列学习。收录于《神经信息处理系统进展》，第3079–3087页。

Jacob Devlin, Ming-Wei Chang, Kenton Lee, 和 Kristina Toutanova. 2018. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805。

杰里米·霍华德和塞巴斯蒂安·鲁德。2018. 用于文本分类的通用语言模型微调。arXiv 预印本 arXiv:1801.06146。

Rie Johnson 和 Tong Zhang. 2017. 用于文本分类的深度金字塔卷积神经网络。收录于《第55届计算语言学协会年会论文集（第1卷：长篇论文）》，第1卷，第562–570页。

Nal Kalchbrenner, Edward Grefenstette, 和 Phil Blunsom. 2014. 用于建模句子的卷积神经网络。arXiv preprint arXiv:1404.2188。

Ryan Kiros, Yukun Zhu, Ruslan R Salakhutdinov, Richard Zemel, Raquel Urtasun, Antonio Torralba, 和 Sanja Fidler. 2015. 跳跃思维向量。载于《神经信息处理系统进展》，第3294–3302页。

Quoc Le 和 Tomas Mikolov. 2014. 句子和文档的分布式表示。收录于《国际机器学习会议》，第1188–1196页。

Zhouhan Lin, Minwei Feng, Cicero Nogueira dos Santos, Mo Yu, Bing Xiang, Bowen Zhou, 和 Yoshua Bengio. 2017. 一种结构化自注意力句子嵌入。arXiv preprint arXiv:1703.03130。

Liyuan Liu, Jingbo Shang, Xiang Ren, Frank Fangzheng Xu, Huan Gui, Jian Peng, 和 Jiawei Han. 2018. 通过任务感知神经语言模型增强序列标注。收录于第三十二届AAAI人工智能会议。

刘鹏飞, 邱希鹏, 和黄宣景。2016. 用于文本分类的多任务学习循环神经网络。arXiv 预印本 arXiv:1605.05101。

Xiaodong Liu, Jianfeng Gao, Xiaodong He, Li Deng, Kevin Duh, 和 Ye-Yi Wang. 2015. 使用多任务深度神经网络进行语义分类和信息检索的表示学习。

Xiaodong Liu, Pengcheng He, Weizhu Chen, and Jianfeng Gao. 2019. 用于自然语言理解的多任务深度神经网络. *arXiv preprint arXiv:1901.11504*.

Lajanugen Logeswaran and Honglak Lee. 2018. 一种高效的句子表示学习框架. *arXiv 预印本 arXiv:1803.02893*.

Andrew L Maas, Raymond E Daly, Peter T Pham, Dan Huang, Andrew Y Ng, and Christopher Potts. 2011. 学习用于情感分析的词向量. 收录于 *第49届计算语言学协会年会论文集: 人类语言技术-第1卷*, 第142–150页. 计算语言学协会.

Bryan McCann, James Bradbury, Caiming Xiong, and Richard Socher. 2017. Learned in translation: Contextualized word vectors. In *Advances in Neural Information Processing Systems*, pages 6294–6305. 迈克尔·麦克洛斯基和尼尔·J·科恩. 1989. 联结主义网络中的灾难性干扰: 序列学习问题. 收录于《*学习与动机心理学*》, 第24卷, 第109–165页. 爱思唯尔.

Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S Corrado, and Jeff Dean. 2013. 词与短语的分布式表示及其组合性. 收录于《*神经信息处理系统进展*》, 第3111–3119页.

杰弗里·彭宁顿、理查德·索彻和克里斯托弗·曼宁. 2014. Glove: 用于词表示的全局向量. 收录于《*2014年自然语言处理经验方法会议 (EMNLP) 论文集*》, 第1532–1543页.

Matthew E Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, and Luke Zettlemoyer. 2018. 深度上下文词表示. *arXiv 预印本 arXiv:1802.05365*.

Chao Qiao, Bo Huang, Guocheng Niu, Daren Li, Daxiang Dong, Wei He, Dianhai Yu, and Hua Wu. 2018. 一种用于文本分类的新区域嵌入方法. 收录于《*国际学习表征会议*》.

Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. 2018. 通过生成式预训练提升语言理解能力. URL https://s3us-west-2.amazonaws.com/openai-assets/researchcovers/languageunsupervised/language_understanding_paper.pdf.

Marek Rei. 2017. 用于序列标注的半监督多任务学习. *arXiv preprint arXiv:1704.07156*.

Minjoon Seo, Sewon Min, Ali Farhadi, and Hannaneh Hajishirzi. 2017. Neural speed reading via skimnn. *arXiv preprint arXiv:1711.02085*.

Dinghan Shen, Yizhe Zhang, Ricardo Henao, Qinliang Su, and Lawrence Carin. 2018. 用于文本序列匹配的去卷积隐变量模型. 载于 *第三十二届AAAI人工智能会议*.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, ukasz Kaiser, and Illia Polosukhin. 2017. 注意力就是你所需要的一切. 收录于《*神经信息处理系统进展*》, 第5998–6008页.

Ellen M Voorhees and Dawn M Tice. 1999. trec-8 问答赛道评估. 收录于 *TREC*, 第1999卷, 第82页. Citeseer.

Canhui Wang, Min Zhang, Shaoping Ma, and Liyun Ru. 2008. 网络环境下的自动在线新闻专题构建. 收录于《*第17届万维网国际会议论文集*》, 第457–466页. ACM.

Yonghui Wu, Mike Schuster, Zhifeng Chen, Quoc V Le, Mohammad Norouzi, Wolfgang Macherey, Maxim Krikun, Yuan Cao, Qin Gao, Klaus Macherey, 等. 2016. 谷歌神经机器翻译系统: 弥合人类与机器翻译之间的差距. *arXiv 预印本 arXiv:1609.08144*.

Zichao Yang, Diyi Yang, Chris Dyer, Xiaodong He, Alex Smola, and Eduard Hovy. 2016. 用于文档分类的分层注意力网络. 收录于《*2016年计算语言学协会北美分会会议论文集: 人类语言技术*》, 第1480–1489页.

Dani Yogatama, Chris Dyer, Wang Ling, and Phil Blunsom. 2017. 使用循环神经网络的生成式和判别式文本分类. *arXiv 预印本 arXiv:1703.01898*.

Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. 2014. 深度神经网络中的特征可迁移性如何? 收录于《*神经信息处理系统进展*》, 第3320–3328页.

Xiang Zhang, Junbo Zhao, and Yann LeCun. 2015. 用于文本分类的字符级卷积网络. 收录于《*神经信息处理系统进展*》, 第649–657页.

Yizhe Zhang, Dinghan Shen, Guoyin Wang, Zhe Gan, Ricardo Henao, and Lawrence Carin. 2017. Deconvolutional paragraph representation learning. In *Advances in Neural Information Processing Systems*, pages 4169–4179.